

学校代码: 1006

学 号:

蘇州大學

SOOCHOW UNIVERSITY

硕士学位论文

(学术学位)



TreeCRF-based High-Order Syntactic Parsing

研究生姓名 _____

指导教师姓名 _____

专 业 名 称 _____

研 究 方 向 _____

所 在 院 部 _____

论文提交日期 _____ 年 月

苏州大学学位论文独创性声明

本人郑重声明：所提交的学位论文是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文不含其他个人或集体已经发表或撰写过的研究成果，也不含为获得苏州大学或其它教育机构的学位证书而使用过的材料。对本文的研究作出重要贡献的个人和集体，均已在文中以明确方式标明。本人承担本声明的法律责任。

论文作者签名： 张宇 日期： 2021.6.8

苏州大学学位论文使用授权声明

本人完全了解苏州大学关于收集、保存和使用学位论文的规定，即：学位论文著作权归属苏州大学。本学位论文电子文档的内容和纸质论文的内容相一致。苏州大学有权向国家图书馆、中国社科院文献信息情报中心、中国科学技术信息研究所（含万方数据电子出版社）、中国学术期刊（光盘版）电子杂志社送交本学位论文的复印件和电子文档，允许论文被查阅和借阅，可以采用影印、缩印或其他复制手段保存和汇编学位论文，可以将学位论文的全部或部分内容编入有关数据库进行检索。

涉密论文 ☐

本学位论文属 _____ 在 _____ 年 _____ 月解密后适用本规定。

非涉密论文 ☒

论文作者签名： 张宇 日期： 2021.6.8

导师签名： 李正华 日期： 2021.6.8

摘要

随着移动互联网与社交媒体的蓬勃发展,包含文本、图像等多模态数据的用户生成内容已成为社会舆情表达的主要载体。多模态方面级情感分析 (Multimodal Aspect-Based Sentiment Analysis, MABSA) 旨在从多模态数据中识别针对特定评价对象的细粒度情感倾向,是当前情感分析领域的研究热点。然而,现有研究多侧重于图文间的显式语义匹配,往往忽视了图文之间隐含的情感关联。在复杂的社交媒体环境下,图像与文本的关系可能呈现互补、无关甚至矛盾的状态,这种情感指向的模糊性与噪声干扰导致模型在处理图文情感不一致场景时鲁棒性不足,且缺乏足够的可解释性。针对上述挑战,本文从图文关系的视角出发,系统研究了基于图文关联的多模态方面级情感分析方法,旨在通过精准刻画图文交互逻辑来提升模型的情感理解能力。本文的主要研究内容与贡献如下:

首先,定义了基于情感表达的方面级图文相关性,并构建了相应的标注数据集。针对现有图文关系定义仅关注全局语义对齐而忽略局部情感关联的局限,本文提出了基于情感表达的细粒度相关性定义,并据此构建了方面级图文相关性数据集。通过系统的数据分析与基准实验,揭示了图文关系类型与情感极性判断之间的内在联系,验证了引入方面级跨模态相关性信息对提升模型性能的有效性。

其次,提出了一种基于图文情感线索引导的多模态方面级情感分析方法。针对现有方法对情感线索建模粒度粗糙的问题,该方法引入多模态大语言模型 (Multimodal Large Language Model, MLLM) 从图像和文本中提取与特定方面相关的情感线索描述,将其作为补充语义编码至上下文表示中。同时,利用细粒度方面级跨模态相关性作为引导信号,控制情感线索与图文特征的自适应融合。实验结果表明,该机制能够有效抑制无关模态或冲突线索的噪声干扰,显著增强了模型对复杂情感表达的理解能力。

最后,提出了一种基于多角度图文相关性解耦的多模态方面级情感分析方法。为进一步提升模型在复杂场景下的鲁棒性,本文将方面级跨模态相关性解耦为语义相关性与情感相关性两个独立维度。通过分别提取图像中的语义与情感特征,并利用解耦后的多角度相关性概率作为门控信号,实现了对特征融合的精细化控制。此外,构建了多任务学习机制,将单模态情感线索从输入端的提示信息转化为训练阶段的监督信号,促使模型主动捕获关键情感特征,从而在有效过滤视觉噪声的同时提升了情

感分析的准确性。

关键词：多模态情感分析；方面级情感分析；图文关系；多模态大语言模型；

作 者：李兆煜

指导老师：付国宏

TreeCRF-based High-Order Syntactic Parsing

Abstract

With the rapid development of mobile internet and social media, user-generated content comprising multimodal data such as text and image become a primary carrier of public sentiment expression. Multimodal Aspect-Based Sentiment Analysis (MABSA), which aims to identify fine-grained sentiment toward specific targets from multimodal data, has emerged as a critical research topic in sentiment analysis. However, existing studies largely focus on explicit semantic alignment between images and text, often overlooking the implicit emotional correlations. In complex social media environments, the relationship between images and text can be complementary, irrelevant, or even contradictory. This ambiguity in emotional orientation and the presence of noise lead to insufficient robustness in existing models when dealing with inconsistent image-text scenarios, as well as a lack of interpretability.

To address these challenges, this thesis investigates MABSA from the perspective of image-text relations, aiming to enhance the model’s emotional understanding by accurately characterizing image-text interactions. The main contents and contributions of this thesis are as follows:

First, this study defines aspect-level image-text relevance based on emotional expression and constructs a corresponding annotated dataset. Addressing the limitation that existing definitions focus merely on global semantic alignment while ignoring local emotional associations, this thesis proposes a fine-grained relevance definition based on emotional expression. Through systematic data analysis and benchmark experiments, the intrinsic link between image-text relation types and sentiment polarity is revealed, verifying the effectiveness of incorporating aspect-level cross-modal relevance in improving model performance.

Second, a MABSA method guided by image-text emotional clues is proposed. Targeting the issue of coarse-grained modeling of emotional clues in existing methods, this approach introduces Multimodal Large Language Models (MLLM) to extract aspect-specific emotional clue descriptions from images and text, encoding them as supplementary semantics into the context representation. Meanwhile, fine-grained aspect-level cross-modal rele-

vance is utilized as a guiding signal to control the adaptive fusion of emotional clues and multimodal features. Experimental results indicate that this mechanism effectively suppresses noise interference from irrelevant modalities or conflicting clues, significantly enhancing the model's ability to comprehend complex emotional expressions.

Finally, a MABSA method based on multi-angle image-text relevance decoupling is presented. To further improve robustness in complex scenarios, this thesis decouples the aspect-level cross-modal relevance into two independent dimensions: semantic relevance and emotional relevance. By separately extracting semantic and emotional features from images and using the decoupled multi-angle relevance probabilities as gating signals, precise control over feature fusion is achieved. Furthermore, a multi-task learning mechanism is constructed to transform single-modal emotional clues from input prompts into supervision signals during the training phase. This encourages the model to actively capture key emotional features, thereby improving the accuracy of sentiment analysis while effectively filtering visual noise.

Key words: Multimodal Sentiment Analysis; Aspect-Level Sentiment Analysis; Image-Text Relation; Multimodal Large Language Model;

Written by Zhaoyu Li

Supervised by Guohong Fu

目 录

第一章 绪论	1
1.1 研究背景	1
1.2 研究意义	2
1.3 国内外研究现状	3
1.3.1 文本方面级情感分析	3
1.3.2 多模态方面级情感分析	4
1.3.3 图文关系推理	6
1.4 研究内容	7
1.5 组织结构	8
第二章 图文情感相关性语料构建与数据分析	10
2.1 引言	10
2.2 图文情感相关性语料构建	11
2.2.1 标注规范	12
2.2.2 人工标注数据构建	13
2.3 方面级情感跨模态相关性数据集分析	15
2.3.1 AECR 标注一致性分析	15
2.3.2 AECR 标签分布	16
2.3.3 与前人工作的标注比较	16
2.3.4 情感标签与相关性标签关系分析	17
2.4 融合跨模态方面级情感相关性的多模态情感分析	18
2.4.1 任务定义	18
2.4.2 现有 MASC 模型的通用架构	18
2.4.3 跨模态情感相关性感知的情感分类增强	20
2.5 实验设置与结果分析	21
2.5.1 评价指标	21
2.5.2 实验参数设置	22
2.5.3 对比实验设置与结果分析	22
2.5.4 消融实验分析	25
2.5.5 在 zero-shot 场景下将跨模态相关性加入到 LLMs 中的性能	27
2.5.6 错误模式分析	27
2.6 本章小结	28

第三章 图文情感线索引导的多模态方面情感分析	29
3.1 引言	29
3.2 基于图文情感线索引导的多模态方面情感分类方法	30
3.2.1 方面级情感跨模态相关性与图文情感线索描述数据集构建	30
3.2.2 相关性引导的生成式框架	31
3.2.3 相关性感知的提示构建	32
3.2.4 编码器输入	33
3.2.5 解码器输出和双流融合	34
3.3 实验设置与结果分析	35
3.3.1 实验参数设置	35
3.3.2 对比实验设置与结果分析	35
3.3.3 消融实验分析	36
3.3.4 相关性质量影响分析	37
3.3.5 超参数分析实验	38
3.3.6 错误模式分析实验	39
3.4 本章小结	40
第四章 多角度相关性解耦的多模态方面级情感分析	41
4.1 引言	41
4.2 基于多角度相关性解耦的多模态方面级情感分析	42
4.2.1 多模态特征解耦抽取	42
4.2.2 多角度相关性建模	44
4.2.3 单模态情感监督	45
4.2.4 自适应融合推理	46
4.2.5 多任务损失函数	47
4.3 实验设置与结果分析	47
4.3.1 实验参数设置	47
4.3.2 对比实验设置与结果分析	47
4.3.3 消融实验分析	48
4.3.4 相关性分析	49
4.3.5 样例分析	51
4.4 本章小结	51
第五章 总结与展望	53
5.1 研究工作总结	53

5.2 下一步工作设想	54
参考文献	55
攻读学位期间的成果	63
致谢	64

第一章 绪论

情感分析是一个热门的研究课题，情感分析的研究场景从文本到多模态，研究对象从句子级到属性级。在技术迭代发展迅速的今天，情感分析的研究也经历了从传统统计模型到深度学习模型的过渡。本课题从图文关系的视角出发，研究多模态情感分析问题，旨在准确识别多模态样本(图文对)蕴含的情感。针对与现有图文关系中忽略了隐含的图文情感关联的问题，因此本课题聚焦图文关系角度去帮助情感分析。本章主要从以下几个方面具体介绍基于图文关系的多模态方面级情感分析研究：首先，介绍本课题的研究背景与意义；随后对国内外相关领域的研究工作进行概述，阐明本研究与前人工作的关联与区别；然后明晰本课题的研究逻辑，并给出具体的研究内容；最后明确本文的组织结构。

1.1 研究背景

情感分析 (Sentiment Analysis) 作为自然语言处理 (Natural Language Processing, NLP) 领域的核心研究方向之一，旨在利用计算技术自动化地识别、提取并量化文本数据中蕴含的主观情绪、观点与态度。随着人工智能技术的演进，情感分析已从单纯的文本分类任务，逐步发展为理解人类认知与社会心理的重要计算手段。伴随着 Web 2.0 技术与移动互联网的飞速发展，社交媒体(如微博、微信、Twitter 等)已彻底重构了人类的信息传播与情感表达方式。相较于传统媒体，社交媒体具有传播即时性、内容多模态性及表达碎片化等特征，成为了公众分享生活点滴与参与公共事务讨论的主要平台。海量的用户生成内容 (UGC) 中不仅包含了文本描述，更融合了图像、视频等多模态数据，这些数据客观记录了社会舆情的动态演变与公众的情感波动^[1,2]。因此，如何从庞杂的多模态数据中挖掘出真实、细腻的情感信息，对于政府及相关机构开展舆情监测与社会治理具有重要的现实意义。高效的情感分析技术能够辅助决策者及时洞察社会情绪风向，为政策制定、品牌声誉管理及公共安全干预提供坚实的数据支撑。

目前情感分析的研究经历了一个由浅入深、由单一到多元的演进过程。早期研究主要聚焦于基于文本的情感分析，依赖情感词典、统计机器学习及深度学习模型进行篇章级或句子级的情感极性分类^[3]。然而，随着网络内容的日益丰富，单模态

分析已难以满足对复杂用户意图的刻画需求，多模态情感分析 (Multimodal Sentiment Analysis, MSA) 因此成为研究热点，致力于融合文本、视觉及声学信息以实现更精准的情感推理。与此同时，为了满足对情感对象更精细化的理解需求，研究粒度也逐渐从粗粒度的全篇/句子级，向细粒度的属性级 (Aspect-level) 深入。这种细粒度的分析要求模型不仅能判断整体情感，还能精准定位特定评价对象 (Aspect) 及其对应的情感倾向。尽管多模态情感分析已取得显著进展，但在复杂的社交媒体环境下仍面临严峻挑战。与传统的文本情感分析不同，社交媒体中的图文内容往往存在情感指向模糊及噪声信息干扰等问题。图片与文本之间可能相互补充、矛盾甚至完全无关，导致模型在融合不同模态信息时容易受到无关信息的干扰。现有基于图文关系的研究通常仅关注图文间的语义匹配关系，而缺乏对图文之间的情感关联的明确定义与建模，忽略了图文之间隐含的情感相关性。这一问题使得模型在面对复杂的社交媒体内容时，难以准确捕捉隐藏于图像与文字交互背后的情感意图，导致其在面对图文情感不一致场景时鲁棒性较差，且缺乏足够的可解释性。

针对上述挑战，本研究提出了一种基于图文关系的多模态情感分析框架，旨在从情感表达角度刻画图文之间的关联。本研究首先着手于定义基于情感表达的方面级图文相关性并在此基础上构建了方面级图文相关性数据集。随后对该数据集进行了系统的数据分析与基准验证实验，揭示了模型在不同图文关系类型下的性能差异。进一步地，本研究提出一种从情感线索角度提出一种多模态方面级情感分析方法，旨在引入多模态大型语言模型 (MLLM) 从图片和文本中提取情感线索，同时建模细粒度方面级跨模态情感相关性来控制，而提升模型对情感表达的理解能力。在此基础上，为探索图文关系在情感分析任务的作用并进一步提高多模态方面级情感分析的性能，本研究将定义的跨模态方面级情感相关性进行解耦为语义与情感两个独立维度进行建模。同时将单模态情感线索从输入提示转化为训练阶段的监督信号，通过多任务学习机制促使模型主动捕获关键情感特征。

1.2 研究意义

多模态情感分析作为跨模态领域的基础任务，其目的是充分理解对用户情感状态的准确识别与推理。其在学术方面和应用方面都具有重要意义。

从学术价值角度，多模态方面级情感分析作为交叉领域的热门课题，能够推动多模态认知智能的发展以及为相关下游任务提供理论范式支撑^[4]。首先传统的单模态

情感分析往往受限于信息维度的单一性，难以捕捉用户在图文场景下的真实意图；而粗粒度的多模态句子级情感分析虽然融合了视觉信息，却忽略了在同一句子中针对不同评价方面可能存在的矛盾情感(例如：“这就餐厅环境很美，但服务太差了”配以精美环境图)。本研究通过聚焦方面级这一细粒度维度，深入探索图文多模态数在特定实体的情感关联。这有助于实现对复杂人类情感的精准建模，从而提升模型在复杂场景下的认知理解能力。其次多模态情感分析能够为多模态嘲讽检测^[5,6]、多模态虚假信息识别^[7]、多模态仇恨检测^[8]等其他相关任务提供有益的技术参考和理论借鉴。

从应用价值角度，多模态方面级情感分析能够将海量的非结构化数据转化为高价值的结构化信息，在社会治理、商业决策及智能服务等领域发挥着不可替代的作用^[9]。例如，在社交媒体上，公众对于突发公共事件、政府政策或社会热点的讨论往往是图文结合的。多模态方面级情感分析技术能够帮助政府及相关监管机构从海量数据中精准定位公众情绪的爆点，在突发灾害或公共卫生事件中，系统不仅能识别整体舆论的负面情绪，还能具体识别出民众是针对救援速度还是信息透明度等具体方面产生不满。这种细粒度的洞察力能够为政府部门提供数据支撑，辅助其及时调整策略，从源头疏导社会情绪，实现精准施策，提升公共危机应对的效率与水平。另外在互联网服务中，多模态方面级情感分析能够显著提升用户体验。例如在智能客服领域，当用户上传一张故障产品图片并附带文字描述时，系统可以准确识别出用户关注的故障“部件以及焦急或愤怒的负面情感。这使得智能客服能够优先处理高情绪强度的投诉，并根据具体问题自动匹配解决方案，实现共情回答。

综上所述，作为一项跨模态情感分析任务，多模态方面级情感分析在学术价值和应用价值上均具有重要意义。

1.3 国内外研究现状

本课题主要针对基于图文关系的多模态方面级情感分析任务展开研究。而如何使用图文关系来帮助多模态方面级情感分析是本课题研究的核心。因此本节主要介绍现有文本方面级情感分析，多模态方面级情感分析和图文关系推理的研究现状。

1.3.1 文本方面级情感分析

文本情感分析，又称意见挖掘 (Opinion Mining)，是自然语言处理领域的一个重要分支，旨在通过计算技术自动化地识别和量化文本中的主观信息与情感倾向。根

据分析粒度的不同,文本情感分析主要分为文档级、句子级和方面级三个层次。早期的研究多集中于文档级和句子级,假设整段文本或单个句子仅包含单一的情感极性。近年来,随着深度学习技术的演进,研究重心逐渐从基于词典和传统机器学习的方法向基于预训练语言模型 (Pre-trained Language Model, PLM) 和大型语言模型 (Large Language Models, LLMs) 的范式转移。然而,在实际应用场景中 (如电商评论或社交媒体反馈), 一条评论往往包含针对多个实体的不同情感评价 (例如: “这家餐厅的菜品很美味, 但服务太慢了”)。这种复杂性使得粗粒度的分析难以满足精细化需求, 从而催生了对方面级情感分析的深入研究^[10]。

方面级情感分析 (Aspect-Based Sentiment Analysis, ABSA) 旨在识别文本中针对特定方面 (Aspect) 的情感极性, 是当前细粒度情感分析的核心任务。现有工作主要围绕注意力机制、预训练模型与图神经网络三大技术路线展开。首先, 早期的基于注意力机制的方法主张通过权重分配策略, 使模型聚焦于与目标方面语义强相关的上下文片段, 以精准捕捉局部情感特征。例如, Wang 等人设计了改进的注意力建模机制, 实现了对不同方面词的差异化聚焦, 有效提升了模型在复杂语境下对情感极性的区分能力^[11]; 而 Chen 等人针对长文本中情感特征传递随距离衰减的问题, 提出了一种结合多尺度特征的注意力网络, 显著增强了模型对长距离上下文情感关联的感知能力^[12], 进一步优化了复杂句式下的情感识别效果。另一方面, 预训练语言模型凭借其在海量语料中习得的深层上下文语义表示能力, 推动了该领域的性能突破。Sun 等人创新性地利用 BERT 模型的深层语义编码能力, 通过构造“文本-方面”输入对并结合依赖树卷积, 显著提升了情感分类的准确性^[13], 这种范式有效地利用了预训练模型的上下文推理能力。最后, 针对序列模型难以捕捉非连续语义依赖的局限, 图神经网络的结构化建模能力为挖掘文本深层句法关联提供了有效工具。Tian 等人提出结合依存句法类型的图卷积模型, 通过构建句法依存图将显式语法结构信息融入情感特征学习过程, 解决了传统 GCN 忽略边类型信息的问题^[14]; Zhang 等人则进一步融合语义相似性与句法依存关系构建增强型图网络, 增强模型对目标方面在复杂语境下的语义感知能力, 有效缓解了歧义上下文及噪声带来的干扰^[15]。

1.3.2 多模态方面级情感分析

多模态情感分析旨在通过融合文本、图像、音频等多种模态的数据, 综合判断目标对象的整体情感极性 (正向、负向或中性)。与单模态分析相比, MSA 能够利用不同模态间的互补性消除单一视角的歧义, 从而提供更鲁棒的情感理解。根据模态融合

阶段的不同,现有研究通常分为特征级融合和决策级融合。早期的特征融合工作多依赖简单的向量拼接,容易忽略模态间的动态交互。近年来,研究者致力于通过注意力机制、张量融合以及图网络等技术来捕捉模态间的深层交互。Zadeh 等人张量融合网络,通过显式融合单模态、双模态和三模态的交互特征,实现了对话语级情感的深度建模^[16]。同时为了在融合过程中充分利用上下文信息,Majumder 等人设计了层次融合策略,通过两两模态逐步整合并结合循环神经网络进行上下文建模,实现了高效的情感预测^[17]。此外,Ghosal 等人上下文跨模态注意力框架,利用注意力机制捕捉话语间的跨模态依赖关系,增强了模型在复杂对话场景下的鲁棒性^[18]。

尽管 MSA 取得了显著进展,但其通常只关注句子或文档的整体情感,忽略了针对具体实体 (Aspect) 的细粒度情感差异。鉴于此,图文对方面级情感分析 (MABSA) 应运而生。该任务以文本-图像对为输入数据,针对文本中指定的目标方面,通过综合推理文本与图像的双模态信息,共同推断该方面对应情感极性。该任务的核心挑战在于如何充分理解并对齐两种异构模态的有效信息,同时有效过滤无关模态带来的噪声干扰。首先,注意力机制驱动的跨模态特征对齐方法延续了文本场景的核心思想,通过构建文本-图像注意力交互模块,利用文本上下文特征动态引导图像相关区域的特征提取。近期,Xu 等人设计了文本方面感知的视觉注意力机制,基于文本语义线索动态聚焦图像中与目标方面强相关的视觉区域^[19]。随后,Yu 等人则提出双向注意力融合框架,实现了文本情感特征与图像视觉特征的相互引导与深层增强^[20,21],从而提升了跨模态情感信息的一致性建模效果。另外,为降低跨模态异构融合的技术复杂度,部分研究采用图像文本化转换策略,试图将图像转换为文本描述后利用成熟的文本情感分析技术完成任务。为此,Wang 等人通过图像描述生成模型将非结构化的视觉内容转化为结构化文本以实现情感判断^[22],受其启发,Xiao 等人与 Zhao 等人分别优化了图像描述生成的细粒度与情感倾向性,使转换后的文本更精准地保留图像中的情感相关信息^[23,24],进一步缩小了视觉与文本模态之间的语义鸿沟。除了将图像转化为文本之外,部分研究考虑直接建模文本与图像的内在相关性,通过过滤无关模态信息提升情感分析的鲁棒性。Ju 等人设计了跨模态关系检测辅助模块,用于前置判断图像是否能为目标方面的情感判断提供额外增益,进而动态调整模态融合权重^[25]。同时,Yu 等人则提出粗粒度-细粒度两级匹配策略,通过文本方面与图像区域的逐层匹配精准判断方面与图像的语义相关性^[26],有效减少了无关视觉背景信息的干扰。此外多模态大模型的兴起为跨模态融合提供了具备强泛化能力的新范式。最近,Feng 等人利用 Q-Former 等视觉语言预训练模型进行指令微调,增强了模型对

方面相关跨模态信息的捕捉与对齐能力^[27]；进一步地，Wang 等人通过融入外部世界知识丰富跨模态上下文，提升模型对隐含情感线索的推理能力，显著优化了复杂场景下的情感分析效果^[28]。

尽管现有多模态方面级情感分类取得了显著进展，但它们通常假设方面已知。但是将方面提取与情感分类分离的处理方式容易导致上游任务的错误传播至下游，且难以捕捉图文间整体的细粒度语义。为解决这一误差累积问题，现有工作逐渐转向联合多模态方面级情感分析 (JMABSA)，旨在在一个统一的框架内同时完成方面项识别与情感极性预测。研究者主要关注如何控制视觉模态的引入以避免噪声干扰，例如 Yang 等人则构建了以文本为中心的 CMMT 框架，利用多任务学习策略监控模态内的表示学习^[29]。随着预训练技术的发展，Ling 等人首次将视觉-语言预训练引入该领域，基于 BART 架构实现了端到端的生成式提取^[30]，随后 Zhou 等人进一步引入方面感知注意力机制与图卷积网络，有效减轻了不同方面间的情感混淆^[31]，同时 Chen 等人应用最优传输理论设计了面向方面的视觉表征过滤机制，有效筛选与方面高度相关的视觉特征^[32]。针对多模态数据中普遍存在的图像噪声与对齐困难，Zhao 等人提出了基于课程学习的多粒度去噪框架 M2DF^[33]，Mu 等人则利用动量对比学习机制显著提升了跨模态特征对齐的精度^[34]。在数据稀缺与复杂场景下，最新的研究如 Yang 等人探索了生成式多模态提示学习^[35]，Xiao 等人更是创新性地将图像审美属性纳入联合任务，利用审美描述辅助情感推理^[36]。此外，为了进一步丰富分析维度，部分研究将任务扩展为“方面-类别-情感”三元组提取，Yang 等人借鉴 T5 架构将该任务重构为解释性句子的生成任务^[37]，而随着大语言模型的兴起，Yang 等人通过指令微调与实体感知对比学习，验证了 ChatGPT¹等大模型在少样本三元组提取任务中的巨大潜力^[38]。

1.3.3 图文关系推理

图文关系推理是指在对文本、图像的内容进行理解的基础上，推断两者之间是否存在语义关联或情感关联的任务。其核心目标是明确不同模态信息的相互作用方式与互补机制，为下游的跨模态理解任务提供逻辑支撑。首先关于图文关系的定义，学术界经历了一系列的演进。早期的研究多针对新闻或网页等结构化较强的领域，致力于构建图文关系的分类体系。早期的研究主要针对漫画书、网页或科研论文等特定数据类型制定分类体系^[39-41]。这些多基于逻辑语义和地位关系，例如根据图文对整体

¹<https://openai.com/zh-Hans-CN/>

意义的贡献是否相等、插图对文本的相似度与延伸程度。然而，随着社交媒体等非结构化数据的激增，研究重点转向了通用场景下的关系定义。**Chen** 等人基于视觉相似性定义相关性，通过计算图像区域特征与文本关键词之间的视觉特征匹配度^[42]。同时，**Vempala** 等人从全局语义角度出发，根据图像是否为文本提供额外信息来定义跨模态相关性^[43]，受这些研究启发，**Wang** 等人则基于文本与图像的语义一致性构建关联模型^[44]。近年来，隐式与情感语义层面的跨模态关系成为研究重点，**Xu** 等人提出关联对齐网络，专门建模文本与图像之间的隐含相关性^[45]，**Chen** 等人则聚焦情感语义对齐，通过计算整幅图像与文本的情感倾向一致性来定义跨模态关系^[46]。

其次对于图文关系推理的方法，主要分为基于特征对齐的推理和基于图结构的推理。早期的推理主要依赖图文检索，即通过全局特征映射来判断整体相关性。**Radford** 等人提出的 **CLIP** 模型通过海量数据的对比学习，确立了基于全局特征对齐的强相关性推理基线^[47]。然而，仅依靠全局特征难以捕捉复杂的局部语义交互。为了实现更深层次的细粒度推理，**Li** 等人提出了 **ALBEF** 框架，通过引入图像-文本匹配头，显式地推理图文对是否匹配^[48]。针对简单的特征对齐难以捕捉结构化关联的问题，**Cheng** 等人提出了跨模态图匹配网络，将图文匹配建模为图节点间的对应问题，利用图卷积网络在模态内和模态间进行关系传播^[49]。此外，针对实际场景中广泛存在的弱相关或噪声数据，**Huang** 等人提出了噪声对应鲁棒性学习方法，通过自适应划分样本来减轻无关图文对推理的干扰^[50]，从而提升了模型在复杂环境下的关系判断能力。

1.4 研究内容

本文从基于图文关系的视角，对多模态方面级情感分析展开研究。针对现有图文关系定义忽略图文间隐式情感关联的问题，本文基于情感表达的方面级图文相关性，构建了一个新的图文数据集以填补空白。在此基础上，本研究依次探索了基于图文情感线索引导的多模态方面级情感分析方法，以及基于多角度相关性解耦的模型增强策略。具体研究内容如下：

(1) 方面级图文情感相关性语料构建与数据分析。本研究从图文关系的视角出发，针对现有图文关系定义仅关注文本与图像的显式对齐或全局相关性，而忽略隐式情感关联，使得模型在复杂场景下易受干扰的。因此本文定义了基于情感表达的方面级跨模态相关性，构建了一个新的方面级图文相关性数据集。在此基础上，本研究对该数据集进行了详细的统计分析，深入探究图文关系与情感之间的内在关联，为后续研

究奠定了数据基础。同时在多个数据集对比了将跨模态相关性信息融入多种多模态方面级情感分类模型，验证了所提出的方面级跨模态相关性的有效性。

(2) 基于图文情感线索引导的多模态方面级情感分析。尽管前述工作验证加入本文提出的方面级跨模态相关性能带来性能提升，但仅依靠粗粒度的相关性难以精确控制图像模态的贡献，同时模型无法精确捕捉单模态中各自蕴含的感线索。使得模型在情感分析场景下的鲁棒性不足。因此，本研究提出了基于图文情感线索引导的多模态方面级情感分析。针对现有方法对图文情感线索建模粒度不足，该方法利用多模态大模型提取与方面相关的情感线索描述，将其作为补充信息编码至上下文；同时利用细粒度方面级跨模态相关性作为引导信号，控制图文情感线索与图文特征的细粒度融合，有效抑制无关或冲突线索的干扰，从而提升模型对图文情感的理解能力。

(3) 基于多角度图文相关性解耦的多模态方面级情感分析。为了进一步提升模型对复杂图文的理解能力和情感识别能力，同时减少对于无关图像语义噪声的引入。本章提出了一种多角度图文相关性解耦的多模态方面级情感分析丰富。为了实现对图像特征的精细化控制，本研究将方面级跨模态相关性进一步解耦为语义相关性与情感相关性两个独立维度进行建模。具体而言，模型分别提取图像中的语义特征和情感特征，并利用解耦后的多角度相关性概率作为门控引导信号；这一机制能够在有效过滤无关语义干扰的同时，针对性地增强关键情感特征的融合与利用。此外，为了夯实多角度相关性建模的基础，本研究引入了单模态情感监督辅助任务。该机制将情感线索从原本的输入端提示转化为训练阶段的监督信号，通过多任务学习促使模型主动习得鲁棒的单模态情感表示，从而显著提升模型在复杂场景下的情感分析能力与鲁棒性。

1.5 组织结构

本文围绕多模态方面级情感分析任务展开研究，总共包含五章，各章的内容具体组织结构如下：

第一章绪论

本章首先介绍了多模态方面级情感分析研究的背景与意义。随后，对相关领域的国内外发展现状进行了概述，指出了现有工作的不足和借鉴之处，最后，阐述了本研究的研究逻辑与研究内容，并展示了论文的主要组织结构

第二章图文情感相关性语料构建与数据分析

本章首先介绍了基于情感表达的方面级图文相关性的定义，并人工标注了 3562 条数据，构建了一个新的方面级图文相关性数据集。在此基础上，为深入了解图文关系和情感分析之间的关联，本研究对构建的数据集进行了详细的数据分析，为后续研究提供了数据基础。同时本研究探索并对比了多种将跨模态相关性信息融入多模态方面级情感分类的方法，在多个数据集中证明了我们提出的方面级跨模态相关性的有效性。

第三章图文情感线索引导的多模态方面级情感分析

本章首先介绍了基于情感线索的多模态方面级情感分析方法。考虑到现有方法对模态中包含的情感线索建模粒度较粗质量差，该方法通过多模态大模型从图片和文本中提取方面相关的情感线索描述，将其作为补充信息编码到上下文中，同时利用该相关性作为引导信号来细粒度使用情感线索和图文情感特征的自适应融合，从而抑制无关或冲突线索的干扰。从而提升模型对情感表达一致性的理解能力。

第四章多角度相关性解耦的多模态方面级情感分析

本章首先介绍了多角度相关性的多模态方面级情感分析方法。该方法通过将跨模态相关性信息解耦为多个方面级相关性，将图文关系解耦为语义与情感两个独立维度进行建模；利用解耦后的多角度相关性特征作为门控引导信号，实现图文特征在语义和情感层面的精确融合。同时，该方法还考虑到将单模态情感线索从输入提示转化为训练阶段的监督信号，通过多任务学习让模型主动理解并捕获情感特征。

第五章总结与展望

本章首先对本研究的研究内容进行了总结，指出了本研究的主要贡献和创新点。随后，对下一步的研究工作方向进行了展望。

第二章 图文情感相关性语料构建与数据分析

现有图文关系定义仅关注文本方面与图像的显式对齐或全局相关性，忽略图文之间隐式情感关联。本章针对该问题从情感表达角度定义方面级跨模态情感相关性，构建数据语料并进行数据分析。同时设计了基于情感相关性感知的多模态方面情感分类模型，为后续研究提供了统一的基准与评估框架。

2.1 引言

多模态方面级情感分类是情感分析领域中一项关键的细粒度任务，其核心目标是判断文本-图像对中针对文本所提及特定方面的情感极性(即积极、消极或中性)。例如在图2-1中，多模态方面级情感分类的任务是识别出针对“Trey Songz”这一特定方面的情感为积极。近年来，多模态方面级情感分类已取得显著进展^[31,51,52]。随着社交媒体平台愈发多地采用多模态内容进行信息传播，精准的多模态方面级情感分类对提升信息理解能力至关重要，同时也能为观点挖掘^[53]、推荐系统^[54]和虚假信息检测^[55]等任务提供有力支持。

与仅考虑单一文本模态的文本情感分析不同，多模态情感分析需要融合文本和视觉语义信息来判断情感极性。因此，在多模态场景中，文本与图像的关系对情感分类起着关键作用：相关图像能够补充文本信息，助力更全面地理解情感；而无关图像则可能引入噪声，误导模型做出错误的情感预测。基于上述考量，已有研究尝试利用图文跨模态相关性来提升情感分析性能。Ju 等人^[25]采用了 Vempala 和 Preoțiuc-Pietro^[43]提出的跨模态关系方案，并取得了性能提升。该方案从全局视角考虑文本整体与图像的关系：当图像能够直观描述或补充文本内容时，即认为其与文本整体相关。尽管该标注方案已被证实对多模态方面级情感分类有益，但在实际辅助多模态方面级情感分类任务时仍存在局限：多模态方面级情感分类的核心是关注文本中每个方面的情感，而在包含多个方面的文本中，单个方面与图像的相关性未必与全局图文相关性一致。仅依赖全局相关性可能引入无关视觉信息，最终导致特定方面的情感判断不准确。例如在图2-1-(a)中，图像与文本整体相关，但“Oklahoma”这一方面与图像无关，此时依赖全局相关性会导致情感预测错误。为捕捉细粒度的方面级跨模态相关性，Yu 等人^[26]提出了一种方面-图像相关性数据集。该方案基于显式对齐来定义文本方面与

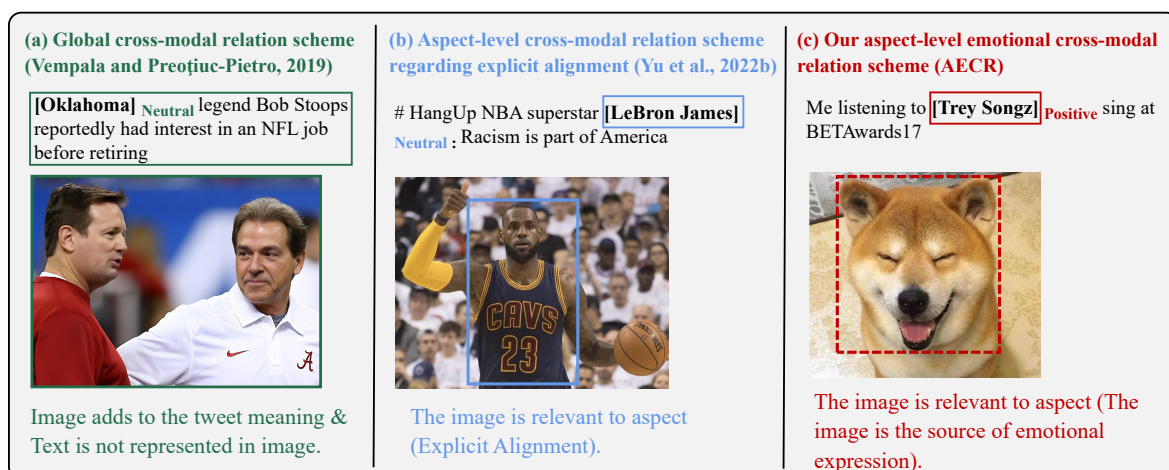


图 2-1 本章提出的跨模态相关性定义与 Vempala^[43] 等人和 Yu^[26] 等人所提出的相关性定义的对比示例。图中的实线框代表显式对齐关系，虚线框则代表隐性情感关联；相应地，文本中的实线框用于突出标注与图中实线框或虚线框内容相关联的文本信息。

图像的相关性，即当图像明确描绘或包含文本中提及的方面时，认为二者相关。如图2-1-(b)中，“勒布朗 詹姆斯 (LeBron James)”这一方面在图像中清晰呈现，因此判定该方面与图像相关。尽管全局跨模态相关性和方面级跨模态相关性均能提升多模态方面级情感分类的性能，但这些方法仍忽略了隐式情感关联，即当方面未在图像中显式出现时，图像仍能增强或传递针对该方面的情感。例如在图2-1-(c)中，“Trey Songz”未在图像中显式出现，但小狗欢快的表情传递了针对该方面的积极情感。

为解决上述局限，本章提出一种方面级情感跨模态相关性 (AECR)，用于捕捉文本的方面与图像间的显式对齐和隐式情感关联。如图2-1所示，尽管“Trey Songz”未在图像中显式呈现，但用户通过图像中小狗的愉悦表情表达了对该方面的积极情感，因此在该跨模态关系方案中，图像与该方面存在隐式情感关联。具体而言，图像是整个图文对的情感来源，因此二者相关。基于该跨模态关系方案，本文构建了方面级情感跨模态相关性数据集 (AECR-Twitter)。为验证所提跨模态关系方案和新构建数据集在下游多模态方面级情感分类任务中的有效性，本章探索并对比了多种将跨模态相关性信息融入多模态方面级情感分类的方法，包括轻量级多模态模型和大型语言模型 (LLMs)，并在 Twitter-15 和 Twitter-17 两个广泛使用的数据集上进行了大量实验。

2.2 图文情感相关性语料构建


本节首先详细介绍图文情感相关性的标注规范以及提供相应的实例说明。紧接着，本节对方面级情感跨模态关系数据集的构建过程进行详细描述，包括标注数据的

Happy birthday [Garrett Walker]**Positive** !



(a) The image is semantically related to the text but emotionally irrelevant

[SamHunt]**Positive** Performs at Stagecoach.



(b) The image is the source of emotional expression

[Justin Bieber]**Negative** broke history and global records but he only won 2 awards.



(c) The image enhances the emotional expression conveyed in the text

Warriors overwhelm [TrailBlazers]**Negative** 110-99 go up 2-0 in series # NBAPlayoffs



(d) The image is irrelevant to aspect

图 2-2 本章中四种相关性类型的示例

选取、标注工具的使用、标注团队的组建与培训以及标注的具体流程

2.2.1 标注规范

本章在综合前人跨模态关系定义^[42,43,45,46]后,并结合多模态方面级情感分类任务特点,提出一种情感语义感知的方面级图文关系标注体系。该方案基于图文对中显式表达的对象和隐式传递的情感语义信息,将图文关系划分为“相关”和“不相关”两类。基于此方案,我们制定了包含详细说明和示例的标注规范,旨在构建高质量的方面级情感跨模态关系数据,为下游方面级情感分析任务提供支持。具体而言,“相关”的图文关系包含以下三种类型:

- 语义相关但情感无关: 图像明确包含文本中提到的方面,但未提供任何相关情感信息。图2-2-(a)给出了一个示例: 图像中包含“Garrett Walker”这一方面(人物实体),但未传递与推文相关的任何情感信息。
- 情感表达来源: 图像中的情感语义信息是判断整体多模态情感的依据,仅依靠

文本无法完成这一判断。例如，在图2-2-(b)中，图像中人物的表情补充了情感表达，明确了文本中对“SamHunt”这一方面的模糊情感倾向，因此该图像可作为该方面的情感来源。

- 增强情感表达：图像通过提供额外的情感语义信息，强化了方面的情感表达。例如，在图2-2-(c)中，图像中女性的悲伤表情，强化了文本中对“Justin Bieber”仅获得两项奖项的遗憾情绪，直观体现了图像对情感表达的增强作用。

“不相关”的图文关系指图文对不属于上述任何一类情况，即图像既不包含文本中提到的方面，也不提供任何额外的情感相关信息。例如，在图2-2-(d)中，方面“TrailBlazers”指NBA开拓者队，但图像展示的是NBA勇士队，因此该图像与“TrailBlazers”这一方面显然不相关。在此情况下考虑图像内容只会引入无关信息。与已有的标注体系不同，以往方案要么仅将文本中的方面与图像中的对象显式对齐时定义为相关^[26]，其余情况均视为不相关；要么聚焦于文本整体与图像的全局相关性^[43,46]，而非方面级相关性。而本文提出的方案同时考虑了文本与图像之间的方面级显式对齐和隐式情感语义关系。这意味着，即使方面未显式出现在图像中，只要图文双方共同参与整体情感的表达，仍将其判定为相关。例如，在图2-2-(c)中，文本中的“Justin Bieber”这一方面与图像中的对象并无显式对齐，但图像强化了对“Justin Bieber”的遗憾和悲伤情绪。识别这种隐式情感相关性，有助于我们更好地利用以往被忽视但有价值的图文关系，最终提升方面级情感分析的性能。

2.2.2 人工标注数据构建

本章采用一套科学的数据标注流程来对图文方面级情感分析数据集进行高质量的人工标注。具体地，为确保标注的准确性，本研究采取严格的双人独立标注方法，即两位标注员进行独立标注，当两位标注员给出不一致的结果时，将由一位第三方专家介入处理这种不一致，以确定最终的正确答案。通过该标注过程，成功构建了一个高质量的多模态方面级图文情感相关性数据集 (Aspect-level Emotional Cross-modal Relation dataset, AEER-Twitter)，该数据集包括 3562 个样本。接下来，本小节将从标注数据的选择、标注工具、标注人员的招聘与培训和标注质量的控制等方面详细介绍数据构建的具体细节。

1. 标注数据的选择

本文构建的方面级情感跨模态关系数据集以 Twitter-17 数据集^[20]为基础, 遵循先前相关研究的做法^[26,46]。Twitter-17 数据集包含从社交媒体平台 Twitter 收集的多模态帖子, 涵盖文本 - 图像对, 且每个文本 - 图像对均标注了文本方面及对应方面的情感极性。我们选取 Twitter-17 数据集中的训练集 (含 3562 个样本) 进行标注, 标注内容包括: 1. 单模态语境下各方面的情感标签; 2. 方面级情感跨模态关系。其中, 单模态语境下的方面情感标注将作为辅助信号, 助力更精准地标注方面级情感跨模态关系类型。随后, 我们将构建的 AEER-Twitter 数据集按 8:1:1 的比例随机划分为训练集、验证集和测试集, 详细统计信息见表 3。值得注意的是, 该数据集经过精心筛选, 已剔除有害内容。

2. 标注工具

图中展示了标注工具的标注界面。对于每个需要标注的图文对, 标注工具会显示该图文对以及目标方面。当根据我们的标注流程, 在我们标注工需要经过三个步骤, 首先是只显示文本和目标方面, 选择目标方面对应的情感极性, 接着第二个步骤中, 标注工具只会显示图片和目标方面, 需要根据图片内容去标注方面的情感, 若图片与方面无关那么需要标注无情感。在最后的步骤中会展示完整的图文对和目标方面, 并提供数据集中已有的金标情感极性, 结合上述信息来分别从信息层面和情感层面来标注方面图文情感相关性。

3. 标注人员的招聘与培训

为了确保数据集的高质量标注, 本研究聘请 4 名具备自然语言处理或多模态分析相关背景的研究生作为标注员, 以及 1 名经验丰富的资深标注员作为专家仲裁。其中, 专家的核心职责是协调并最终裁决标注过程中出现的分歧。所有标注人员的报酬是根据他们的标注质量和完成的工作量来决定的, 以此激励标注员严谨、细致地执行标注任务。为确保标注判断的全面性与客观性, 我们为每个推文图文对设计了“分阶段递进”的标注流程, 避免标注员仅凭单一模态信息仓促下结论:

- 第一步 (文本单模态标注): 仅向标注员提供推文文本和对应的方面实体, 要求其仅基于纯文本内容判断该方面的情感极性, 旨在建立纯文本维度的情感基准, 为后续跨模态关系判断提供参考。

- 第二步 (图像单模态标注): 仅向标注员提供图像和对应的方面实体, 要求其仅基于视觉内容 (如图像中的人物表情、场景氛围等) 判断该方面的情感倾向, 用于获取纯视觉维度的情感线索, 与文本维度形成互补。
- 第三步 (方面级图文情感相关性判断): 向标注员完整呈现图文对, 并提供 Twitter-17 数据集中已有的多模态方面级情感标签作为参考, 要求标注员结合前两步的独立判断结果, 综合评估并最终确定“方面级情感跨模态关系”的具体类型。这种“先分后合”的流程, 能有效减少单一模态信息的误导, 提升跨模态关系判断的准确性。

在正式启动标注工作前, 所有标注员需参加专项培训: 一方面, 详细解读标注准则 (包括 4 种关系类型的定义、边界案例的判断标准等), 通过典型示例演示帮助标注员形成统一认知; 另一方面, 指导标注员熟练操作我们自主开发的标注工具, 确保其能高效、规范地记录标注结果, 避免因工具使用不熟练或对规则理解不一致导致的系统性误差。

4. 标注质量的控制

在标注过程中, 本研究基于开发的标注工具进行严格的独立双重标注, 以保证标注数据的质量, 工作流程如图所示。具体来说, 每个图文对被随机分配给两名不同的标注者, 由二者独立完成方面级情感相关性标注; 若两名标注者的标注结果一致, 则直接将该结果作为最终标注; 若结果不一致, 由第三位专家标注者在分析双方标注后确定最终答案。

2.3 方面级情感跨模态相关性数据集分析

为了评估构建的 AEER-Twitter 数据集的质量, 本节对其进行了标注一致性分析。此外, 为了探索相关性标签和情感标签的相关关系, 以及方面级图文情感相关性和前人标注体系的区别, 本节从不同的角度对对标注的 AEER-Twitter 数据集进行了分析。

2.3.1 AEER 标注一致性分析

在标注过程中每项标注任务会分配给两名标注者进行独立标注。我们针对标注完成的跨模态关系计算了标注者间一致性比例, 结果显示 84% 的任务中两名标注者得出了一致结果, 另有 16% 的任务需由第三位专家标注者进行进一步审核。经调查

表 2-1 我们的 AECR-Twitter 数据集标签分布情况

Relevance	Type	Number	Proportion
Relevant	The image is semantically related to the text but emotionally irrelevant	868	24.37%
	The image enhances the emotional expression conveyed in the text	730	20.49%
	The image is the source of emotional expression	248	6.96%
Irrelevant	The image is irrelevant to aspect	1,716	48.18%

表 2-2 与前人工作的标注比较

	Relevant	Irrelevant
Yu 等 ^[26]	39.1%	60.9%
Our annotation	45.3%	54.7%
	(Explicit: 37.7% Implicit: 7.6%)	

发现，标注不一致主要原因在于标注者对图像和文本中情感表达的解读存在差异。这表明，执行严格的双重标注是保障数据质量的关键。

2.3.2 AECR 标签分布

表2-1展示了 AECR 数据集中标签的分布情况。由表可以得知，其中，“Irrelevant” (无关) 标签占比 48.18%。这一现象反映了社交媒体平台的内容特性，主要由两方面原因造成。首先，在同时包含多个方面 (aspect) 的推文中，图像通常只与其中一个方面相关，而与其他方面无关。其次，用户在发布推文时也可能附上与文本内容完全无关的图像。对于 “Relevant” (相关) 标签，最常见的类型是：图像呈现了文本中的方面，但不包含任何情感信息，占比 24.37%。第二常见的类型是图像通过提供额外的情感线索来增强文本的情感表达。最少见的类型是推文的情感完全通过图像传达。这表明用户更倾向于使用文本作为表达情感的主要模态，而图像通常用于辅助文本；仅通过图像传递情感的情况相对较少。

2.3.3 与前人工作的标注比较

我们将数据集中相关与无关标签的分布与已有研究进行对比，并在表2-2中给出了显性与隐性相关性的比例。与 Yu 等^[26] 相比，其仅将具有显性对齐关系的文本-图像对视为相关，而忽略了隐性的情感关联，因此我们的数据集由于纳入了隐性的跨模




图 2-3 AEER-Twitter 数据集中不同相关性类型与情感类别之间的分布情况

态相关性，具有更高比例的相关标签。在我们的所标注的相关性类型中，显性相关与隐性相关分别占 37.7% 和 7.6%。这表明，在图文相关的场景中，大约六分之一的情感表达是通过隐含情感关联的图像 (如表情包等) 来传递的。与以往的跨模态关系标注方案相比，我们的方法能够更有效地捕捉图像与文本之间这些隐性的情感联系，从而更好地支持下游的多模态方面级情感分类 (MASC) 任务。

2.3.4 情感标签与相关性标签关系分析

我们分析不同相关性类型与情感类别之间的关系。如图2-3所示，当情感为中性时，占比最高的情况是该方面与图像无关，其次是图像与方面在语义上相关但不包含情感联系的情况。这表明，当用户对某一方面实体没有情感倾向时，图像往往与该方面无关，或仅作为描述性补充。在积极情感的场景中，占比最高的情况是图像能够增强方面的情感表达，说明用户倾向于通过文本与图像的共同作用来强化积极情绪。在消极情感中，图像无关、语义相关但情感无关，以及图像增强情感表达三类情况的比例较为接近。这说明负面情绪的表达方式更加多样化。

2.4 融合跨模态方面级情感相关性的多模态情感分析

本章提出的方法主要由三个部分构成。首先，我们给出了任务的形式化定义，明确界定了基于方面的跨模态关系推理任务、多模态方面级情感分类（MASC）任务，以及两者之间的内在联系。其次，我们总结了现有 MASC 模型采用的通用架构。最后，我们详细阐述了本文提出的模块，旨在引入方面级的情感跨模态相关性。

2.4.1 任务定义

为了降低无关图像的干扰并提升情感分类性能，我们将本文提出的“方面级情感跨模态相关性”引入到 MASC 任务中。具体而言，基于方面的跨模态关系推理任务旨在预测图像与文本中给定方面之间的相关性。随后，利用该相关性概率抑制无关图像的影响，从而改进多模态方面级情感分类任务的效果。

具体来说，数据集中的每个样本 $\mathbf{x}$ 包含一条推文，该推文由文本-图像对及其对应的方面组成。其中， x^t 、 x^i 和 x^a 分别表示文本、图像和方面。文本 x^t 是由 n 个单词组成的句子；而方面 x^a 是指文本中的命名实体（如人名、地名或组织名），它是 x^t 的一个包含 m 个单词的子序列。

基于方面的跨模态关系推理形式化为一个二分类问题。给定输入 $\mathbf{x} = (x^t, x^i, x^a)$ ，其目标是预测图像 x^i 与文本 x^t 针对给定方面 x^a 的关系 r ，其中 $r \in \{relevant, irrelevant\}$ 。

多模态方面级情感分类旨在针对给定文本 x^t 和图像 x^i 对中的方面 x^a ，预测其情感极性标签 $y \in \{positive, neutral, negative\}$ 。

2.4.2 现有 MASC 模型的通用架构

基础 MASC 模型的架构主要包含三个核心组件：文本/视觉编码器用于将文本和图像编码为特征表示；方面感知提取模块提取两个模态中聚焦于方面相关信息的特征表示；情感分类模块则融合文本和视觉特征以获得多模态表示，并将其输入 Softmax 层进行情感预测。

文本/视觉编码器。给定输入 $\mathbf{x} = (x^t, x^i, x^a)$ （包含文本-图像对及一个方面），我们分别使用文本编码器和视觉编码器来提取文本和视觉模态的上下文特征表示。对于文本编码器，我们采用 RoBERTa^[56] 或 BERT^[57] 对文本 x^t 和方面 x^a 的拼接序列进行编码。对于视觉编码器，我们利用 Faster R-CNN^[58] 或 ViT^[59]。最终得到的文本和图




图 2-4 EmoCRel-MASC 架构概览

像表示分别记为 $\mathbf{h}^t$ 和 $\mathbf{h}^i$ 。

方面感知提取模块。在获得文本和图像表示后，我们将它们输入到方面感知提取模块中。该模块从文本和图像中提取并提炼与方面相关的表示。该模块可以通过多种方法实现，其中包括 ITM^[26]、HIMT^[60] 和 DPFN^[22] 等框架中的模块。对于方面感知的文本表示，应用注意力机制或依存句法分析器等方法来获取方面感知的文本表示 $\mathbf{h}^{a2t}$ 。对于方面感知的视觉表示，则应用跨模态 Transformer (CMT)^[61] 等方法来捕获方面感知的视觉表示 $\mathbf{h}^{a2i}$ 。

情感分类模块。我们通常采用 Wang 等^[22] 中的拼接方法或 Yu 等^[26,60] 中的 Transformer 方法来生成最终的多模态融合表示 $\mathbf{h}^f$ 。随后，我们将 $\mathbf{h}^f$ 输入 Softmax 层，以预测情感标签 $\mathbf{y}$ 的概率分布，从而进行情感分类：

$$p(\mathbf{y}) = \text{Softmax}(\mathbf{W}_s \mathbf{h}^f + \mathbf{b}_s) \quad (2.1)$$

在训练过程中，对于每个输入 $\mathbf{x}$ ，我们使用交叉熵损失最大化真实情感标签 y^* 的概率，目标函数如下：

$$\mathcal{L}_s = -\log P(y^*) \quad (2.2)$$

2.4.3 跨模态情感相关性感知的情感分类增强

如图 2-4 所示，我们提出了一种跨模态情感相关性感知的多模态方面级情感分类方法（EmoCRel-MASC），旨在将预测的相关性有效地整合到 MASC 任务中。跨模态关系推理模块输出一个相关性概率，用于控制图像的贡献度；我们使用 AEER-Twitter 数据集作为监督信号来训练该模块。随后，关系感知的多模态融合模块利用预测的相关性概率来指导文本和视觉特征的融合，从而有效地抑制无关图像的影响。

方面级情感跨模态关系推理。为了将本文提出的方面级情感跨模态关系引入 MASC 任务，我们采用了一个跨模态关系推理模块来执行基于方面的跨模态关系推理，并获取相应的相关性概率。该概率用于控制图像的贡献度，并减少无关图像的干扰。具体而言，我们首先应用跨模态 Transformer（CMT）来捕获跨模态图像表示，其中图像表示 $\mathbf{h}^i$ 作为查询向量 $\mathbf{q}$ ，文本表示 $\mathbf{h}^t$ 作为 Key $\mathbf{k}$ 和 Value $\mathbf{v}$ 。接着，执行最大池化操作以获取用于跨模态关系推理的最显著跨模态特征 $\mathbf{h}^{t2i}$ ：

$$\mathbf{h}^{t2i} = \text{maxpool}(\text{CMT}(\mathbf{h}^i, \mathbf{h}^t, \mathbf{h}^t)) \quad (2.3)$$

最终的相关性概率计算如下。值得注意的是，我们将该模块预测为“相关”类别的概率作为相关性概率。

$$p(\mathbf{r}) = \text{Sigmoid}(\mathbf{W}_r \mathbf{h}^{t2i} + \mathbf{b}_r) \quad (2.4)$$

关系感知的跨模态融合。为了缓解 MASC 任务中无关图像的干扰，我们设计了一个关系感知的多模态融合模块，利用相关性概率引导模型关注相关图像，同时最小化无关图像的影响。具体而言，我们首先利用方面感知视觉提取模块来获取方面感知的视觉表示 $\mathbf{h}^{a2i}$ 。然后，我们将跨模态相关性概率 $p(r)$ 进行广播（broadcast）以匹配 $\mathbf{h}^{a2i}$ 的维度，得到矩阵 $\mathbf{R}$ 。该矩阵 $\mathbf{R}$ 被用作权重，通过逐元素乘法获得关系感知的跨模态表示 $\mathbf{h}^r$ ：

$$\mathbf{h}^r = \mathbf{R} \odot \mathbf{h}^{a2i} \quad (2.5)$$

例如，当相关性概率 $\mathbf{R}$ 趋近于 0 时，表明图像与文本不相关，模型相应地在多模态融合过程中降低视觉特征的贡献。最后，我们将关系感知的跨模态表示 $\mathbf{h}^r$ 和方面感知

的文本表示 $\mathbf{h}^{a2t}$ 输入到上述多模态融合模块中，生成增强的多模态融合表示 $\mathbf{h}^{AECR-f}$ 。随后，我们将 $\mathbf{h}^{AECR-f}$ 作为最终的多模态特征输入 **Softmax** 层进行情感分类。此外，对于每个输入 $\mathbf{x}$ ，我们使用两个独立的交叉熵损失函数来分别最大化其真实跨模态关系标签 r^* 和真实情感标签 y^* 的概率，联合目标函数为：

$$\mathcal{L} = \mathcal{L}_s + \mathcal{L}_r = -\log P(y^*) - \log P(r^*) \quad (2.6)$$

在推理阶段，我们选择得分最高的标签作为预测的情感标签。

2.5 实验设置与结果分析

2.5.1 评价指标

本课题的图文多模态方面级情感分类问题是一个典型的分类任务，我们使用正确率 (Accuracy, Acc) 和宏平均 F1 值 (F1) 来评估性能。其中，F1 值是精确率 (Precision) 和召回率 (Recall) 的加权调和平均。在这些指标中，正确率既可以用于评估二分类系统的性能，也可以用于评估多分类系统的性能。而精确率、召回率和 F1 值则只能用于评估二分类系统的性能。本节将简要介绍以上评价指标在多分类系统中的定义，它们的计算公式如下：

$$\text{Accuracy} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{TN} + \text{FP} + \text{FN}} \quad (2.7)$$

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}} \quad (2.8)$$

$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}} \quad (2.9)$$

$$\text{F1} = \frac{2 \times \text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \quad (2.10)$$

其中，TP表示该类被模型正确分类的样本数，FP表示其他类别被不正确地分类到该类别的样本数，FN表示该类被不正确地分类到其他类别的总样本数，TN表示其他类别被正确地分类到其他类别的总样本数。

2.5.2 实验参数设置

本研究中对于基线模型 ITM、HIMT、DPFN、A2II、AoM 和 DQPSA，我们遵循其原始设置。为了引入相关性信息，我们使用 AECR-Twitter 数据集来训练跨模态关系推理模块。该模块为基线模型提供关系感知知识，指导多模态融合过程，并有助于减轻不相关图像的影响。在 Qwen2-VL 中，我们使用了两个独立的 Qwen2-VL-7B 模型，并采用 LoRA^[62] 进行微调，学习率设为 $1e-4$ 。为了引入相关性信息，第一个 Qwen2-VL 模型在 AECR-Twitter 数据集上进行了微调。随后，该模型被用于生成 Twitter-15 和 Twitter-17 数据集的预测相关性标签。第二个模型针对 MASC 进行微调，其中预测的相关性被包含在指令中，以指导模型抑制不相关图像。对于 Qwen2.5-VL，我们使用 Qwen2.5-VL-7B 模型，并采用与 Qwen2-VL 相同的实验设置。所有模型均使用 PyTorch 框架实现，并在 NVIDIA Tesla V100 GPU 上运行。我们使用三个不同的随机种子进行实验，并报告平均性能。我们采用 Dan Bikel 的随机评估比较器进行显著性检验^[40]。

2.5.3 对比实验设置与结果分析

为了验证本章提出方法的有效性，本节在自建数据集 AECR-Twitter，Twitter-15 和 Twitter-17 数据集上，与以下几种相关基线模型进行了对比实验，详细的统计数据见表??：

- ITM^[26]：该方法提出了粗粒度与细粒度图像-aspect 对齐的多任务学习框架。由于 ITM 原本使用 Yu 等人提出的 aspect-image 相关性数据集来进行基于 aspect 的跨模态关系推理，我们在“ITM + Our AECR”中将其替换为我们的 AECR-Twitter 数据集，用于训练跨模态关系推理模块。
- HIMT^[60]：该方法分层交互式多模态 Transformer 模型。在“HIMT + Our AECR”中，我们将跨模态关系推理模块集成到 HIMT 中，以获取图像与 aspect 之间的相关性权重。
- DPFN^[22]：该方法双视角融合网络，用于同时建模特定 aspect 相关的全局与局部细粒度情感信息。在“DPFN + Our AECR”中，我们采用与“HIMT + Our AECR”相同的方式注入我们的相关性信息。
- A2II^[27]：一种生成式模型，通过利用语言-视觉大模型 (LVLMs) 解决多模态融

合的局限，并通过指令微调减轻无关图像噪声的影响。在“A2II + Our AECR”中，我们使用基于 AECR-Twitter 数据集微调后的 Qwen2-VL-7B 模型生成的关系感知知识，替换其原本由 InstructBlip-Flan-T5-xl^[63] 模型生成的知识。

- Qwen2-VL^[64]：一种广泛使用的 LVLM，表现出良好的性能。“Qwen2-VL + Our AECR”表示在指令中注入我们的关系感知知识。
- Qwen2.5-VL^[65]：Qwen2-VL 的升级版，具有更强的视觉-语言对齐能力与推理能力。“Qwen2.5-VL + Our AECR”沿用与“Qwen2-VL + Our AECR”相同的关系感知知识注入策略。
- AoM^[31]：该方法面向 aspect 的方法，通过图卷积网络 (GCN) 在句法依存条件下融合语义与情感特征。“AoM + Our AECR”指采用与“A2II + Our AECR”相同的策略，将我们的关系感知知识注入 AoM 中。
- DQPSA^[52]：该方法通过双查询提示实现视觉-文本对齐，并使用能量模型进行 span 边界配对。在“DQPSA + Our AECR”中，我们采用与“A2II + Our AECR”相同的方式，将我们提出的关系感知知识注入 DQPSA。

表 2-3 展示了各模型在 Twitter-15、Twitter-17 以及 AECR-Twitter 数据集上的多模态方面级情感分类 (MASC) 主要实验结果。其中，ITM、HIMT、DPFN、A2II、AoM 和 DQPSA 的实验结果均由我们重新实现。符号 $\dagger$ 表示该模型与引入 Our AECR 后的对应模型之间的性能差异在显著性水平 $p < 0.01$ 下具有统计显著性，而符号 $\diamond$ 表示差异不显著 ($p > 0.05$)。

实验结果表明，在引入我们提出的情感感知跨模态相关性后，所有模型均取得了稳定且一致的性能提升。尤其是在当前两种先进方法 AoM 和 DQPSA 上，同样观察到了显著的性能增益，充分验证了所提出相关性建模方法的有效性。我们将性能提升主要归因于跨模态关系推理模块与所提出相关性建模机制的协同作用：一方面，该关系推理模块能够有效帮助现有 MASC 方法抑制无关图像带来的干扰，从而提升情感分析性能；另一方面，我们提出的相关性不仅能够建模文本 aspect 与图像之间的显式对齐关系，还能够捕获二者之间隐式的情感关联，使得 aspect-image 相关性建模更加全面。

此外，Qwen2.5-VL 与 DQPSA 相较于其他模型表现出更为优越的性能，这主要得益于语言-视觉大模型 (LVLMs) 所具备的强大多模态理解能力以及视觉-语言预训练任务的有效性。在此基础上，引入我们提出的跨模态相关性进一步提升了 Qwen2.5-VL

表 2-3 对比实验结果

Methods	Twitter-15		Twitter-17		AECR-Twitter	
	ACC	F1	ACC	F1	ACC	F1
ITM	77.78	73.44	71.64	70.27	71.72	67.23
ITM+Our AECR	78.36 [†] _{±0.20}	74.09 [†] _{±0.11}	72.93 [†] _{±0.91}	71.86 [†] _{±0.76}	73.31 [†] _{±0.39}	69.17 [†] _{±0.55}
HIMT	76.01	71.46	67.77	65.34	68.31	62.05
HIMT+Our AECR	76.37 [°] _{±0.43}	72.01 [†] _{±0.20}	68.82 [†] _{±0.12}	66.88 [†] _{±0.18}	69.94 [†] _{±1.18}	63.88 [†] _{±0.12}
DPFN	76.75	71.72	70.06	68.68	66.29	65.96
DPFN+Our AECR	76.53 [°] _{±0.31}	72.46 [†] _{±0.37}	71.12 [†] _{±0.40}	69.38 [†] _{±0.32}	71.06 [†] _{±1.20}	70.85 [†] _{±1.21}
A2II	76.61	72.70	72.96	71.37	71.15	66.96
A2II+Our AECR	77.77 [†] _{±0.07}	73.13 [†] _{±0.35}	74.11 [†] _{±0.38}	72.74 [†] _{±0.38}	72.19 [†] _{±0.48}	68.63 [†] _{±0.67}
Qwen2-VL	77.91	73.41	72.69	71.07	71.91	67.12
Qwen2-VL+Our AECR	79.36 [†] _{±0.72}	74.25 [†] _{±0.36}	73.39 [†] _{±0.12}	72.61 [†] _{±0.29}	73.68 [†] _{±1.13}	70.06 [†] _{±1.13}
Qwen2.5-VL	77.62	73.73	74.31	73.95	72.75	68.30
Qwen2.5-VL+Our AECR	78.73 [†] _{±0.07}	74.19 [†] _{±0.07}	74.55[†]_{±0.11}	74.40[†]_{±0.36}	73.87 [†] _{±0.28}	71.10 [†] _{±0.02}
AoM	77.90	73.84	73.52	72.38	73.37	70.17
AoM+Our AECR	78.52 [†] _{±0.23}	75.08 [†] _{±0.25}	74.02 [†] _{±0.09}	72.92 [†] _{±0.31}	74.15[†]_{±0.24}	72.05[†]_{±0.40}
DQPSA	80.80	80.80	71.88	71.88	71.34	71.34
DQPSA+Our AECR	81.65[†]_{±0.20}	81.65[†]_{±0.20}	72.89 [†] _{±0.29}	72.89 [†] _{±0.29}	72.28 [†] _{±0.42}	72.28 [†] _{±0.42}

和 DQPSA 的性能,进一步验证了情感感知跨模态相关性在增强 MASC 性能方面的有效性。在 Twitter-15 数据集上, DQPSA 的性能优于 Qwen2.5-VL。我们认为,这一优势来源于其在预训练阶段采用了基于提示的图像理解机制,使模型能够更加精准地关注与给定 aspect 相关的图像区域,从而实现更准确的情感预测。相比之下,“Qwen2.5-VL + Our AECR”在 Twitter-17 数据集上取得了更优的结果,这主要归因于其更强的泛化能力。然而,在 AECR-Twitter 数据集上, Qwen2.5-VL 的表现仍略逊于 AoM 和 DQPSA,这可能是由于 Qwen2.5-VL 需要更多训练数据才能充分适配任务,而 AoM 与 DQPSA 在小规模数据集上更具优势。

总体而言,我们提出的情感感知跨模态相关性在所有模型架构上均带来了稳定一致的性能提升,充分体现了其在捕获隐式情感关联以及提升多模态方面级情感分析性能方面的鲁棒性与有效性。

表 2-4 消融实验结果

Methods	AECR-Twitter	
	ACC	F1
Complete Model	73.31	69.17
without “Irrelevant” type	63.34	57.69
without “Emotional expression source” type	72.46	68.44
without “Enhancing emotional expression” type	71.62	67.36
without “Semantically related but emotional irrelevant” type	71.20	67.05

2.5.4 消融实验分析

为了更好地理解每种关系类型的贡献,如表2-4所示,我们在 AECR-Twitter 数据集上进行了一项消融实验,每次省略一个跨模态关系类型,并对比实验结果,具体见表格。”Complete Model”表示包含所有四种关系类型的 MASC 模型,而 “without x type”则表示在执行 MASC 时忽略了关系类型 x。需要注意的是,在消融实验中,训练集的大小保持不变。当去除某个关系类型时,我们保留完整数据集用于训练 MASC 任务,同时在基于方面的跨模态关系推断任务中屏蔽该类型的监督信号。

表格2-4展示了消融实验的结果。我们首先观察到,去除任何一种关系类型都会导致相较于 “Complete Model” 的一致性性能下降,这表明所有关系类型都对 MASC 任务有积极贡献。特别地,去除 “无关” 类型会导致最显著的性能下降。我们将其归

LLM Prompt Template

Task Definition: Detect the sentiment polarity towards the aspect from the sentence. Strictly format output as [sentiment]. If cross-modal relation is relevant, integrate the information of the sentence and the image description to make predictions. if cross-modal relation is irrelevant, only use the sentence to make predictions.

Aspect: Trey Songz

Options: -positive -neutral -negative

Make sentiment prediction for the following sentence:

Sentence: Me listening to Trey Songz sing at BET Awards17.

Image Description : The image is about a dog smiling happily. The image implies happy sentiment. The entity of the dog is present in the image.

Cross-modal relation: relevant

图 2-5 Relevance-aware zero-shot prompt template.

因于社交媒体中普遍存在的弱图像-文本对齐现象，排除这类样本会严重削弱模型过滤跨模态噪声的能力。此外，去除“增强情感表达”和“语义相关但情感无关”类型会导致显著下降。这突出了这两种类型的重要作用：前者通过视觉上的隐性情感线索强化了文本情感表达，而后者则帮助模型区分情感相关性与语义相关性，有效捕捉图像中的关键信息。去除“情感表达来源”类型对性能的影响较小。这可能是因为该类型在数据集中占比较低，导致模型未能充分学习该类型的模式。

表 2-5 将跨模态相关性加入到 LLMs 中在 Twitter-15 和 Twitter-17 上的结果

Methods	Twitter-15		Twitter-17	
	ACC	F1	ACC	F1
GPT-3.5-Turbo	48.72	49.72	51.95	48.31
GPT-3.5-Turbo+Our AECR	52.49	52.36	52.55	49.25
Qwen-Turbo	65.19	59.80	57.37	54.57
Qwen-Turbo+Our AECR	68.56	61.83	59.72	56.02
DeepSeek-V3	62.64	61.64	59.40	58.87
DeepSeek-V3+Our AECR	66.12	63.67	62.53	61.29




图 2-6 错误模式的统计分析。其中“Pos”、“Neu”和“Neg”分别代表正面、中性和负面

2.5.5 在 zero-shot 场景下将跨模态相关性加入到 LLMs 中的性能

我们进一步通过 zero-shot 场景下的提示，探讨了我們提出的方面级情感跨模态关系在增强各种 LLMs 的能力方面的有效性。图 2-5 显示了我们设计的提示模板。具体来说，任务定义概述了 MASC 任务，并解释了如何利用跨模态相关性进行 MASC。在提示中，我们提供了方面、情感选项和推文中的句子。图像描述是从 BLIP-Image 和 BLIP-VQA 中提取的，依据^[38]，并包含图像标题、视觉实体描述和视觉情感描述。对于跨模态关系，我们在 AECR-Twitter 数据集上微调了 Qwen2-VL-7B 模型，以生成跨模态关系感知的知识。我们评估了多种开源和闭源 LLMs 的 MASC 性能，包括 DeepSeek-V3、GPT-3.5-Turbo 和 Qwen-Turbo。如表 2-5 所示，所有 LLMs 在 zero-shot 场景下融入跨模态关系感知知识后，均表现出一致的性能提升。这一观察表明，我们的关系感知知识提高了 LLMs 在 MASC 任务中的可靠性。特别地，开源 LLMs DeepSeek-V3 和 Qwen-Turbo 在两个数据集上都优于闭源的 GPT-3.5-Turbo。

2.5.6 错误模式分析

为了更好地理解我们方法所取得的改进，我们分析了在^[26]框架下，不同对比模型在错误模式上的变化。一个错误模式 X, Y 表示黄金情感标签“X”被错误地预测为“Y”或反之。图 2-6 显示了 Twitter-17 数据集上的结果。我们观察到，在三种错误模式中，“Neu, Pos”和“Neu, Neg”的错误发生最为频繁，表明区分中性情感与积

极或消极情感仍然是一个主要挑战。这些错误通常发生在图像中的情感线索模糊时，导致模型预测出更强的情感。通过引入我们的关系感知，模型能够更好地利用图像中的隐性情感线索，区分中性情感与其他两个情感标签。相比之下，“Neg, Pos”错误模式出现的频率最低，但通常涉及讽刺或冲突的多模态线索。例如，一条表达消极情感的推文可能伴随一张积极的图像，这可能会误导模型做出错误的预测。我们的方法通过对与方面无关的图像进行降权，减轻了一个问题，使模型能够更专注于讽刺性的文本线索。尽管我们的模型在处理这种类型的错误时比^[26]表现得更好，但仍略微不如基准模型。我们将在未来的工作中探讨合适的方法来解决这一类型的错误。

2.6 本章小结

本章定义了方面级情感相关性，并基于相关性的定义构建了一个方面级情感跨模态相关性数据集（AEER-Twitter），该数据集包含 3562 个样本。本章详细描述了 AEER-Twitter 的构建过程，涵盖了从标注规范到人工标注数据的全部流程，为确保数据集的高质量，本研究采用严格的独立双重标注。此外本章对 AEER-Twitter 数据集进行深入的分析，包括标注一致性分析、相关性标签分布、与前人定义相关性比较以及相关性标签与情感标签的关系分布。同时为验证所提跨模态关系方案和 AEER-Twitter 数据集在下游多模态方面级情感分类任务中的有效性，本章探索并对比了多种将跨模态相关性信息融入多模态方面级情感分类的方法，包括轻量级多模态模型的相关性插件方法和通过 prompt 注入相关性的大型语言模型方式，在 Twitter-15，Twitter-17 和 AEER-Twitter 数据集的实验结果表明加入我们提出的方面级情感相关性能够给现有方法提供一致的性能提升，验证了我们提出的方面级情感相关性的有效性。此外，本章将对方面级情感相关性进行了详细的分析，包括相关性标签类型的消融实验，错误模式的分析，深入探索了方面级情感图文相关关系的特点。

第三章 图文情感线索引导的多模态方面情感分析

第二章提出的 EmoCRel-MASC 方法，将定义的方面级跨模态情感相关性融入到多模态方面级情感分类方法中，通过计算文本与图像之间的情感相关性，来减少无关图像信息的干扰。然而已有的方法忽略了细粒度的情感跨模态相关性的使用以及对模态中情感线索的挖掘，难以准确捕捉与目标方面强相关的特定情感特征。针对上述问题，本章提出了一种基于细粒度相关性控制与情感线索引导的多模态方面级情感分类方法。具体而言，本设计了一个离线数据增强模块，利用大模型从原始数据中提取显式的情感线索描述与细粒度的相关性标签；随后，在训练阶段根据相关性标签动态调整图文提示的构建策略，并采用两路分支的后期融合机制，有效抑制无关模态的干扰，突出与目标方面真正相关的情感信号。

3.1 引言

在第二章的工作中，我们定义了方面级情感相关性，基于相关性定义构建了情感相关性数据集。同时为验证提出的相关性的有效，我们提出了一种相关性感知的多模态方面级情感分类方法，通过相关性插件将相关性信息以图像权重比例的方式注入到模型之中。实验结果在多个模型和多个数据集得到了一致的提升表明了加入我们相关性的有效性。然而，现有方法在建模模态图文的情感线索时，主要通过全局的视觉特征或单一的文本语义 `embedding` 来代表模态情绪，但真实场景中的情绪线索往往分布在更细粒度的层面。例如，用户在文本中可能使用比喻、隐含情绪或未显式提及评价对象的表达方式；图像中的颜色、表情、场景构成等细节也可能蕴含间接的情绪信息。如果仅使用粗粒度的模态表示，模型难以准确捕捉这些细微却关键的情绪因素，从而导致情感识别偏差。另一方面。在上一章的工作主要通过计算图文是否相关的粗粒度权重系数来控制图像特征的使用，这种方式缺乏对细粒度情感相关性的深度挖掘。在复杂的实际场景中，图像中可能包含与文本情感无关的干扰背景，若仅进行粗粒度的权重调节，模型往往难以精确调控不同线索对最终情感决策的贡献，容易受到噪声干扰。面对上述问题，本章认为可以引入多模态大语言模型 (MLLM) 通过显式知识增强的方式提升特征质量。基于该思路，本章提出了一种基于 MLLM 知识增强与细粒度相关性控制的多模态方面级情感分类方法。该方法首先利用 MLLM 抽取图像与文本中的情感线索描述，使得隐含的模态情绪信息能够以自然语言形式显

式表达，也通过文本化的方式弥合模态间的表征差异；其次，基于情感相关性构建差异化的输入指令，引导模型在关注有用线索的同时主动忽略无关信息的干扰；最后，设计了一种两路分支的后期融合机制，实现对文本与图像分支占比的灵活调节。总的来说，本章工作的主要贡献如下：- 显式情感知识增强机制：本章提出利用 MLLM 强大的推理能力，显式地从原始模态中抽取深层的情感线索描述。通过将隐式的视觉特征转化为显式的文本语义线索，显著提升了情感特征的判别性与质量。- 基于相关性的精细化线索控制：本章设计了一套基于情感相关性的指令构建策略。通过在输入端引入不同类型的引导指令，使模型能够根据线索的贡献度进行动态调整，有效解决了由于线索粒度过粗而导致的抗噪能力弱的问题。- 可控的多路融合架构：本章提出了一种两路分支的后期融合方式。根据情感相关性标签调节两条分支的贡献比例，从而有效抑制无关或冲突模态的影响，突出真正与 **aspect** 相关的模态情绪信号。

3.2 基于图文情感线索引导的多模态方面情感分类方法

本章提出了一种基于相关性控制与情感线索引导的多模态方面级情感分类方法 (RC-ECG)。具体来说，该方法首先利用多模态大模型的强大能力来获得细粒度的方面级情感跨模态相关性，并从图像和文本中提取显式的、与方面相关的情感线索描述，为后续的分类任务提供参考信息。得到了包含情感线索描述和方面级情感跨模态相关性标签的扩充数据集。接着在相关性引导的情感线索训练阶段中，该方法根据情感线索描述和相关性标签来动态构建文本分支与图像分支的提示输入，筛选出与目标方面相关的情感线索。最后该方法设计了一种两路分支的后期融合机制，根据情感相关性标签调节两条分支的贡献比例，从而有效抑制无关或冲突模态的影响，突出真正与目标方面相关的模态情绪信号。

3.2.1 方面级情感跨模态相关性与图文情感线索描述数据集构建

为满足本章提出的基于相关性控制与情感线索引导的多模态方面情感分类方法，该方法为每个样本添加方面级情感跨模态相关性标签与情感线索描述。因此首先需要基于原有的图文对来构建情感线索描述和方面级情感跨模态相关性标签。具体来说分别使用 Qwen2.5-VL-7B 模型和 Gemini 2.5 来进行数据集的扩充。整体的构建流程如图所示，接下来是数据构建的具体细节：

方面级情感跨模态相关性标签生成。对于数据集中的样本 $x = x^t, x^a, x^i$ ，为了精准




图 3-1 RC-ECG 架构概览

描述其中图像 x^i 与文本 x^t 中方面 x^a 之间的情感跨模态相关性，选用在视觉理解与推理任务上表现优异的 Qwen2.5-VL-7B 模型作为方面级情感跨模态相关性的分类器。具体来说，基于上一章构建的 AECD-Twitter 数据集，对 Qwen2.5-VL-7B 进行指令微调，然后在 Twitter-15 和 Twitter-17 数据集进行推理，使其能够根据图文内容输出三分类标签 $r \in \{0, 1, 2\}$ 。这些标签将作为后续生成式框架中引导情感线索组合使用的核心控制信号，用于控制使用与目标方面相关的情感线索。

- 无关 ($r = 0$)：图像内容与文本或目标方面存在矛盾或无关联，视为噪声。
- 语义相关 ($r = 1$)：图像在语义信息上与文本一致，但未包含明显的情感倾向。
- 情感相关 ($r = 2$)：图像表达或加强了针对目标方面的情感表达。

图文情感线索描述生成。为了弥补小参数模型在情感理解能力上的不足，该方法利用 MLLM 的强大的推理能力提取显式的情感线索描述作为一种知识蒸馏的方式。通过构建 prompt 调用 MLLM 分别从图像 x^i 与文本 x^t 中提取方面 x^a 相关的情感线索描述。具体来说，对于图像情感线索描述 c^i ，输入图片和目标方面词 x^a ，要求模型输出与 x^a 相关的情感线索描述。而对于文本情感线索描述 c^t ，输入文本 x^t 和目标方面词 x^a ，要求模型输出与 x^a 相关的情感线索描述。具体的 prompt 如表3-1所示。

3.2.2 相关性引导的生成式框架

在相关性引导的情感线索训练阶段中，本章根据上一节得到的情感线索描述和相关性标签来动态构建文本分支与图像分支的提示输入到该生成式框架中。具体来说，该框架主要由相关性感知的提示构建、图文输入编码、以及两路分支融合三

表 3-1 图文情感线索描述 Prompt

Prompt Type	LLM Prompt
textual sentiment clue prompt	Given the sentence: "{text}". What is the opinion towards "{aspect}" in this sentence? Base your answer solely on the information in the sentence. Respond in one or two sentences.
visual sentiment clue prompt	Please describe the emotion expressed in the image. Try to be concise while ensuring the correctness of your answers.

个模块组成。

3.2.3 相关性感知的提示构建

为了减轻无关情感线索的干扰，本章设计了一种方面级情感跨模态相关性感知的提示工程策略。构建了两个输入序列：文本分支提示, X_{txt} 和图像分支提示 X_{multi} 。其构建逻辑严格受控于方面级情感跨模态相关性标签 r ：文本分支提示 (X_{txt})，该分支专注于文本模态的情感线索描述。将输入文本 T 、目标方面 x^a 以及提取的文本线索 c^i 按照标准模板进行拼接：

$$X_t = "[\text{Instruction}], \text{Sentence: } T, \text{Sentence Emotion: } c^i \text{Aspect: } A" \quad (3.1)$$

图像分支提示，该分支旨在融入图像模态的情感线索描述，但通过相关性标签 r 进行控制是否引入。具体构建逻辑如下：

$$X_i = \begin{cases} \mathcal{T}_{irrel}(T, A), & \text{if } r \in \{1, 0\} \\ \mathcal{T}_{rel}(T, A, c^i), & \text{if } r == 2 \end{cases} \quad (3.2)$$

具体而言，当 $r \in \{1, 0\}$ （无关）时，我们丢弃图像线索 c^i ，并使用一条限制性指令 $\mathcal{T}_{irrel}$ ，强制模型忽略视觉输入。其中对于限制模型忽略视觉输入的 Instruction 为：“ $\mathcal{T}_{irrel}$ ”。 $r == 2$ （相关）时，我们整合 c^i 并使用一条协同指令 $\mathcal{T}_{rel}$ ，结合图像情感线索 c^i 来引导模型关注与目标方面相关的情感线索。其中协同指令的 Instruction 为：“ $\mathcal{T}_{rel}$ ”。具体而言， $\mathcal{T}_{rel}$ 模板为：

$$\mathcal{T}_{rel}(T, A, c^i) = "[\text{Instruction}], \text{Sentence: } T, \text{Image Emotion: } c^i \text{Aspect: } A" \quad (3.3)$$

3.2.4 编码器输入

在本小节中，模型的输入层旨在将图文模态特征统一映射至预训练语言模型的语义空间。我们分别对视觉特征和文本提示进行处理，构建包含视觉前缀的序列化嵌入。具体来说，对于图像特征的编码，我们参考前人的工作利用强大的 MLLM 来获得图像中与方面相关的图像特征，首先对于图像 x^i ，我们使用冻结的图像编码器 ViT-g/14 来提取图像特征 $\mathbf{h}^{img}$ ，然后我们创建一组可学习的查询嵌入 $\mathbf{q}$ ，这些查询可以通过自注意力层与方面特征交互，也可以通过交叉注意力层与图像特征交互。正如 InstructBLIP 将图像特征和指令一起输入到 Q-Former 中，以使查询 $\mathbf{z}$ 提取出指令所描述的任务信息更丰富的图像特征一样，我们也同时将图像特征 $\mathbf{h}^i$ 和方面 x^a 输入到 Q-Former 中，以获得与图像方面相关的细粒度特征。由于 Q-Former 已经过预先训练，可以通过查询提取包含语言信息的视觉表示，因此它可以有效地充当信息瓶颈，提供最有用的信息，同时过滤掉不相关的视觉信息。最后，我们得到最终的隐藏状态表示 $\mathbf{h}^f$ 。值得注意的是，文本分支与图像分支共享该投影模块的参数，这有助于模型在统一的视觉语义空间下进行推理。对应的数学公式，vit 和 q-former 部分 Q-Former 编码：

$$\mathbf{h}^i = \text{Q-Former}(\mathbf{h}^{img}, \mathbf{x}^a) \quad (3.4)$$

接着基于前文构建的文本主导提示序列 X_{txt} 与多模态主导提示序列 X_{img} ，我们首先通过冻结的 T5 词嵌入层 $\text{Embed}(\cdot)$ 将其转换为离散的文本嵌入分别得到 $\mathbf{E}_{txt}, \mathbf{E}_{img}$ 。随后得到的 Q-Former 的隐藏状态表示 $\mathbf{h}^i$ 经过一个线性层 $\text{Proj}(\cdot)$ 映射至与 T5 词嵌入维度相同的空间，得到 $\mathbf{h}^p$ 。将生成的软视觉前缀 $\mathbf{h}^p$ 分别拼接至两个分支的文本嵌入序列前端，形成最终的编码器输入：

$$\begin{aligned} \mathbf{h}_{txt} &= [\mathbf{h}^p; \mathbf{E}_{txt}] \\ \mathbf{h}_{img} &= [\mathbf{h}^p; \mathbf{E}_{img}] \end{aligned} \quad (3.5)$$

其中 $[\cdot; \cdot]$ 表示在序列长度维度上的级联操作。通过这种前缀注入机制，双流分支在接收相同视觉信息的同时，受到不同指令与情感线索的引导，从而实现差异化的特征编码。

表 3-2 对比实验结果

Methods	Twitter-15		Twitter-17	
	ACC	F1	ACC	F1
ITM	78.36	74.09	72.93	71.86
HIMT	76.37	72.01	68.82	66.88
DPFN	76.53	72.46	71.12	69.38
Aom	77.9	73.84	73.52	72.38
Qwen2-VL-7B	79.36	74.25	73.39	72.61
Qwen2.5-VL-7B	77.62	73.73	74.31	73.95
Base Model	77.77	73.13	74.11	72.74
Prompt Fuse Method	77.14	74.20	74.06	73.35
Our Method	77.91	75.27	74.80	74.36

3.2.5 解码器输出和双流融合

构建好的输入嵌入 $\mathbf{h}_{txt}$ 与 $\mathbf{h}_{img}$ 被并行输入至参数共享的 Flan-T5 生成式模型中。为了综合利用文本模态的稳定性与视觉模态的丰富性，我们在解码阶段采用逻辑层融合策略。具体来说，我们通过引入一个可调节的平衡超参数 $w \in [0, 1]$ ，对两个分支的进行加权求和，得到最终的融合表示 $\mathbf{h}^f$ ：

$$\mathbf{h}^f = w \cdot \mathbf{h}_{txt} + (1 - w) \cdot \mathbf{h}_{img} \quad (3.6)$$

接着使用最终的融合表示 $\mathbf{h}^f$ 输入到 Softmax 层，用于预测情感极性类别 $\mathbf{y}$ 的概率分布。

$$p(\mathbf{y}) = \text{Softmax}(\mathbf{W}_s \mathbf{h}^f + \mathbf{b}_s) \quad (3.7)$$

在整个训练过程采用端到端的监督学习方式。我们采用标准的交叉熵损失函数来最大化真实情感标签 y^* 的概率，目标函数如下：

$$\mathcal{L}_s = -\log P(y^*) \quad (3.8)$$

3.3 实验设置与结果分析

3.3.1 实验参数设置

本章采用预训练的 FlanT5-base 模型^[66] 作为语言模型以编码文本特征, 该模型是基于 Transformer 结构的指令微调模型^[67]。图像特征编码采用 ViT-g/14^[68], 随后通过 instructblip-flan-t5-xl^[69] 的 Q-Former 模型实现图像特征与方面的交互, 以获取与方面相关的细粒度图像特征。针对图文情感线索的提取, 利用 Gemini 2.0¹模型, 根据文本和图像的情感线索提示, 分别提取相应的文本与图像情感线索描述。实验在每个数据集的验证集上微调超参数, 期间保持图像编码器处于冻结状态。模型参数优化采用 AdamW 优化器^[70], 整体训练过程的学习率设为 $5e-5$, 训练轮数 (epoch) 设为 20, 批处理大小设为 16。输入序列和输出序列 (及情感极性) 的最大长度分别设为 150 和 5。Q-Former 和语言模型的隐藏层维度均设为 768。所有模型均基于 PyTorch 实现, 并在 NVIDIA Tesla V100 GPU 上运行。

3.3.2 对比实验设置与结果分析

如表 3-2 所示, 我们将本文提出的方法与现有的主流基准模型进行了对比, 实验结论分析如下:

(1) 相较于基准方法, 本章提出的模型 (Our Method) 在两个数据集上均取得了极具竞争力的表现。特别是在 Twitter-17 数据集上, 本章方法在 ACC 和 F1 值上均大幅超越了所有对比模型。在 Twitter-15 数据集上, 尽管 Qwen2-VL-7B 在准确率上略有优势, 但本章方法取得了最高的 F1 值。

(2) 通过与 Base Model 和 Prompt Fuse Method 的对比, 进一步证实了细粒度相关性控制与情感线索引导机制的关键作用。具体来说, Base Model 仅使用二分类相关性来加权图像特征, 缺乏明确的情感语义描述引导, 导致模型难以充分挖掘图文对中的深层情感交互, 限制了性能上限。而 Prompt Fuse Method 简单地将图文情感线索拼接在输入端, 这种粗粒度的融合方式不仅未能有效利用描述信息, 反而可能引入语义噪声, 导致模型无法聚焦于关键特征。相比之下, 本章方法通过细粒度的相关性控制与显式的情感线索引导, 有效解决了上述问题, 显著提升了模型对 MASC 任务的适配能力。

¹<https://deepmind.google/models/gemini/>

(3) 虽然 Qwen 系列大模型拥有庞大的参数规模，并在 Twitter-15 的准确率上表现出色，但本章方法在 Twitter-17 的各项指标以及 Twitter-15 的 F1 值上均实现了反超。这表明，在面向 MASC 这类细粒度情感分析任务时，单纯依赖模型参数规模的堆叠并非最优解。通用大模型往往缺乏针对特定图文关系的精细化建模，而本文设计的相关性控制与情感引导机制，能够以更小的参数规模实现更精准的任务特征提取，展现了针对特定任务进行结构化设计的优越性。

表 3-3 消融实验结果

Model Name	Twitter-15		Twitter-17	
	ACC	F1	ACC	F1
Complete Model	77.91	75.27	74.79	74.36
w/o Relevance Control	76.66	71.82	71.31	70.62
w/o Emotional Clues	77.77	73.13	74.11	72.74
w/o Relevance and Emotional Clues	76.60	72.70	72.96	71.37
w/o Relevance and Text Emotional Clue	77.91	74.50	72.77	71.36
w/o Relevance and Image Emotional Clue	75.89	71.74	74.14	73.61

3.3.3 消融实验分析

为了验证本章提出的相关性控制模块与图文情感线索的有效性，我们在 Twitter-15 和 Twitter-17 数据集上设计了消融实验：

-w/o Relevance Control: 保留图文情感线索，但移除相关性控制模块。此设置用于验证在缺乏相关性约束时，直接引入线索是否有效。

-w/o Emotional Clues: 保留相关性控制模块，但移除所有情感线索。此设置用于验证情感线索是否为模型性能提供了重要线索。

-w/o Relevance and Emotional Clues: 同时移除相关性控制和所有情感线索。

-w/o Relevance and Text/Image Emotional Clue: 在移除相关性控制的基础上，分别仅保留图像情感线索或仅保留文本情感线索，用于探究不同模态线索对特定数据集的贡献差异。

实验结果如表3-3所示，可以得出以下结论：(1) 相较于完整模型 (Complete Model)，移除任意模块后的变体在 F1 指标上均出现了不同程度的下滑。这充分证明了细粒度

相关性控制与多模态情感线索的结合能够显著增强模型对图文对的情感理解能力,对于提升方面级情感分类任务的判别准确性至关重要。

(2) 与移除情感线索引导相比,移除相关性控制模块的实验对模型性能的影响更大,如果仅引入情感线索而缺乏相关性控制,其性能甚至低于没有任何线索的基准模型。表明简单的图文线索堆叠会引入特征冲突或噪声。相关性控制模块在此处起到了关键作用,能够有效过滤无关信息的干扰,解决图文线索冲突问题,确保模型仅利用与目标方面强相关的情感描述。

(3) 在分别单独引入图像或文本线索的实验中,我们观察到了一个显著的现象:在 Twitter-15 数据集上,保留图像线索的性能显著优于保留文本线索。这是由于该数据集多包含单一方面目标,图像内容通常直接反映了核心情感,具有较高的信息增益。相反,在 Twitter-17 数据集上,保留文本线索的表现更佳。这是因为 Twitter-17 包含大量多方面的样本,复杂的图像背景往往成为噪声,难以对应到具体的特定方面,此时模型更依赖于文本描述中的精确语义线索。

表 3-4 相关性质量分析结果

Model Name	Twitter-15		Twitter-17	
	ACC	F1	ACC	F1
with Coarse-grained Relevance	77.04	73.76	74.87	73.98
with Fine-grained Relevance	77.91	75.27	74.80	74.36
Add 20% Relevance Noise	77.53	73.41	74.23	72.76
Add 50% Relevance Noise	76.47	73.22	72.77	72.20

3.3.4 相关性质量影响分析

为了深入探究相关性控制模块的质量对模型最终性能的具体影响,我们设计了针对相关性的对比实验。包含以下三种设置:

-粗粒度相关性 (Coarse-grained Relevance): 将相关性退化为二值控制,即仅区分图文是否相关,忽略了相关程度的强弱差异。

-细粒度相关性 (Fine-grained Relevance): 即本文提出的完整方法,将图文情感相关性分类为情感相关、语义相关和图文无关三种情况。

-相关性噪声干扰 (Relevance Noise): 为了验证模型对低质量相关性的敏感度,我




图 3-2 不同超参数分析

们在细粒度相关性的基础上引入人工噪声。具体而言，我们随机选择 20% 和 50% 的测试样本，将其的相关性类型替换为随机类型，以此模拟相关性计算失效或对齐错误的情况。

实验结果如表 3-4 所示，可以得出以下结论：对比粗粒度与细粒度相关性的实验结果表明，精细化的相关性建模对于提升模型性能至关重要。在 F1 指标上，细粒度相关性设置在两个数据集中均取得了最优结果。我们认为二元相关性判定不足以捕捉复杂图文对中情感关联，而细粒度相关性能够识别情感相关的图文对保留对情感分类有贡献的关键模态线索。另外通过引入不同比例的噪声干扰，我们观察到模型性能呈现出明显的下降趋势。当引入 20% 的噪声时，模型在两个数据集上的 F1 值均出现了下滑；而当噪声比例增加至 50% 时，性能损失进一步扩大。说明了模型对相关性质量的依赖，进一步验证了本文所提出的相关性控制模块在保证图文特征对齐质量方面的核心作用。

3.3.5 超参数分析实验

本节深入探讨了双路分支融合权重 w 对模型整体性能的影响。在 RC-ECG 框架中， w 作为一个关键的调节因子，用于控制两路分支（文本主导分支与图像主导分支）在最终决策层面的贡献比例。我们在 Twitter-17 数据集进行实验将 w 从 0.2 逐步调整至 0.8。




图 3-3 测试集种不同错误模式统计

实验结果如图3-2所示，我们观察到当权重值设置较小（ $w = 0.2$ 至 $w = 0.4$ ）时，模型的 F1 值在逐渐上升，表明此时模型未能充分利用辅助模态的情感互补信息。进一步观察 $w > 0.5$ 的区间，可以发现模型性能呈现出明显的下降趋势。当 w 增加至 0.6 和 0.8 时，F1 值反而下降；这一性能衰减表明在 Twitter-17 数据集中由于图文关系较为复杂，过度依赖单一特定分支存在较大风险。在 w 趋近于 1.0 的极端情况下，模型实际上忽略了另一路分支的语义输入，这种信息的偏差不仅引入了潜在的模态噪声，还破坏了多模态信息的完整性，导致模型在处理图文情感不一致时鲁棒性降低。

3.3.6 错误模式分析实验

为了更深入了解我们的方法带来的改进，本小节分析了我们的方法和 base model 之间错误模式数量的变化，其中错误模式“gold→pred”表示正确标签为 gold，而错误预测为了标签 pred。

图3-3展示了在 Twitter-17 数据集的结果，我们观察到 RC-ECG 模型在降低误判为中性方面表现显著，充分验证了本文所提出的情感线索引导机制的有效性，即通过显式引入多模态情感线索，模型能够更敏感地捕捉到输入中存在的细微情感特征，从而避免了将带有情感倾向的样本分类为中性。另外对于将负面情感误判为正面情感的极性反转类型的错误。RC-ECG 将此类错误的数量大幅减少。主要得益于提出的相关性控制机制，模型能够有效抑制模态间的冲突或无关噪声。当图像与文本在情感表达上出现不一致时，通过相关性标签动态调节构造输入，模型能够更准确地锁定主

导情感的模态。除此之外，对于中性情感被误判为正面或负面情感的数量在 RC-ECG 中略微增加。这表明我们的方法通过 MLLM 提取并利用情感线索时，倾向于过度解读多模态信息中的情感信号，这是我们未来工作中需要重点关注方向。

3.4 本章小结

本章针对现有多模态方面级情感分类任务中情感线索粒度较粗、跨模态相关性挖掘不足以及易受无关噪声干扰等问题，提出了一种基于相关性控制与情感线索引导的多模态分类方法（RC-ECG）。首先，本章介绍了基于多模态大语言模型的数据增强策略，通过提取细粒度情感跨模态相关性标签与显式的情感线索描述，构建了包含丰富语义信息的扩充数据集，为后续模型训练提供了高质量的先验知识。其次，详细阐述了 RC-ECG 模型的整体架构与关键模块。该方法采用双阶段框架，在在线训练阶段，设计了相关性引导的动态提示构建机制，依据相关性标签差异化构造文本与图像分支的输入，有效筛选关键情感线索。同时，提出了基于两路分支的后期融合机制，通过加权调节不同模态分支的贡献比例，实现了对模态噪声的有效抑制与特定方面情感信号的增强。最后，在 Twitter-15 和 Twitter-17 两个基准数据集上进行了广泛的对比实验与深入分析。实验结果表明，本章提出的方法在各项评价指标上均优于现有的主流基准模型。此外，通过消融实验、相关性质量分析、超参数敏感性分析及错误模式统计，进一步验证了细粒度相关性控制模块与情感线索引导机制在提升模型鲁棒性和情感判别能力方面的有效性。

第四章 多角度相关性解耦的多模态方面级情感分析

第三章提出的图文情感线索引导方法通过引入细粒度的方面级跨模态情感相关性标签和单模态情感线索描述，增强了模型对图文情感交互的理解，并利用细粒度相关性有效提升了多模态方面级情感分类的性能。然而该方法在处理图文关系时仍存在局限性：当模型依据图像信息时，往往结合了图像中的无关语义信息。这些无关的物体或场景信息作为视觉噪声对最终的情感判断产生干扰。为了实现对图像视觉特征的更精细化利用，本章提出将方面级跨模态情感相关性解耦为情感相关性和语义相关性两个独立维度。通过这种多角度的解耦策略，模型能够分别控制图像中语义特征和情感特征的权重，在过滤无关语义噪声的同时，针对性地增强有效情感特征的利用，从而进一步提升多模态方面级情感分类的性能。此外，本章还提出了基于单模态情感监督增强辅助任务，旨在增强模型对文本和图像自身情感内容的理解基础。

4.1 引言

第三章提出的方法通过引入细粒度的方面级跨模态情感相关性标签和单模态情感线索描述，有效地辅助了模型理解图文之间的情感语义关联，进而提升了多模态方面级情感分类任务的表现。然而，该方法对相关性的利用主要依赖于“情感相关”、“语义相关”和“图文无关”三种互斥的离散类别。虽然这种分类方式宏观上兼顾了情感与语义因素，但在细粒度的特征交互层面，尚未实现对图像情感特征与语义特征的独立解耦与控制。我们认为在处理复杂样本时，若不加区分地引入整幅图像特征，图像背景中夹杂的冗余语义信息往往会作为噪声掩盖关键的情感线索。

针对上述局限性，本章致力于进一步优化图文相关性建模机制，通过挖掘深层次的方面级跨模态关联，实现对图像情感特征和语义特征的解耦与精细化利用，从而显著提升模型对图文内容中情感信息与语义信息的理解深度。基于该思路，我们将方面级跨模态相关性明确解耦为情感相关性和语义相关性两个独立视角，分别用于指导图像情感特征和图像语义特征的自适应加权与互补融合。在特征提取层面，本章利用多模态模型，通过设计针对性的文本指令作为引导信号，定向获取图像的细粒度情感特征与语义特征。

此外，为了确保模型具备稳健的多模态关联建模能力，本章提出了一种渐进式的

两阶段训练框架。第一阶段设定为单模态情感监督和多角度相关性预测的辅助任务，作为预热训练阶段，通过将文本情感分类、图像情感分类和多角度相关性建模作为辅助监督信号，强化模型对单模态基础情感特征的识别能力以及对图文深层次关联的先验理解；第二阶段则开展以多模态方面级情感分类为主的多任务联合学习，利用解耦后的情感相关性和语义相关性概率分布，动态调节对应图像特征的介入程度，实现特征的细粒度控制。在 Twitter-15 和 Twitter-17 数据集上的实验结果表明，本章提出的基于多角度相关性解耦的多任务框架能够有效削减模态噪声，提升模型的分类性能。

4.2 基于多角度相关性解耦的多模态方面级情感分析

本章提出一种基于多角度相关性解耦的多模态方面级情感分析框架如图所示4-1。该框架包含多模态特征解耦抽取、多角度相关性建模、单模态情感监督以及自适应融合推理四个核心模块。为提取细粒度的图像情感与语义特征，模型采用多模态理解组件，通过构造特定的自然语言指令，实现了语义导向特征与情感导向特征的精细化分离。针对上一章章节获取的细粒度方面级跨模态情感相关性标签，框架将其进一步解耦为情感相关性与语义相关性，并结合文本特征，利用两个独立网络分别预测图像在内容与情感层面与方面词的相关性。预测得到的概率作为门控信号，对细粒度视觉特征进行动态加权。此外，为增强模型对单模态情感信息的理解，本文引入文本与图像情感分类作为辅助任务，利用图文情感线索中的单模态标签进行监督训练。最终，经过门控过滤的视觉特征与文本特征深度融合，输入生成式模型以预测最终情感标签。

4.2.1 多模态特征解耦抽取

对于输入样本 $x = \{x^t, x^a, x^i\}$ 及情感标签 y ，文本模态的处理方式与 3.2.4 节一致，即采用预训练 T5 模型对文本进行编码，获取 Embedding 表示 $E^t = \text{T5}(x^t, x^a)$ 。在图像模态方面，本小节采用预训练 InstructBLIP 模型提取与方面词相关的细粒度视觉特征。InstructBLIP 创新性地引入了 Q-Former(Querying Transformer) 组件作为连接视觉与语言模态的桥梁。类似于 Transformer 在自然语言处理中的作用，Q-Former 包含一组可学习的 Query 向量，这些向量通过交叉注意力机制与冻结的图像编码器输出进行交互，从而捕捉关键的视觉信息。更为关键的是，Q-Former 具备指令跟随能力，能




图 4-1 DMRD-MASC 架构概览

够将自然语言文本作为条件输入引入特征提取过程。与传统视觉模型生成固定、通用的图像表征不同，Q-Former 能够根据不同的文本提示词，动态调整注意力权重，从图像中选择性地感知并提取与指令语义高度对齐的局部特征。基于此特性，本文通过构造差异化的指令，分别引导 Q-Former 聚焦于图像的客观语义内容与主观情感线索，从而实现视觉信息的精细化解耦。

具体来说，在图像语义特征提取阶段，以图像 x^i 和方面词 x^a 为输入，构造语义提取提示词 P_{sem} （具体为“Task: Describe the aspects related to x^a in the image: x^i ”）。通过将方面词嵌入模板，利用 Q-Former 提取语义导向的视觉特征：

$$\mathbf{V}_{sem} = \text{Q-Former}(x^i, P_{sem}) \quad (4.1)$$

同样地，针对图像情感特征，构造提示词 P_{emo} （具体为“Task: Analyze the emotional relevance of aspect x^a in the image: x^i ”），进而提取情感导向的视觉特征：

$$\mathbf{V}_{emo} = \text{Q-Former}(x^i, P_{emo}) \quad (4.2)$$

4.2.2 多角度相关性建模

多角度相关性定义。为充分挖掘细粒度的跨模态相关性，我们将关联性解耦为语义与情感两个维度，分别控制不同层面视觉特征的利用率。具体定义了两个二值标签：语义相关性 $y_{sem}^* \in \{0, 1\}$ 用于指示图像在语义层面是否与方面词 x^a 相关；情感相关性 $y_{emo}^* \in \{0, 1\}$ 则指示图像在情感表达层面是否与方面词相关。相关性判别网络的训练利用前序章节生成的解耦伪标签作为监督信号，分别对两个维度的相关性进行预测。

多角度相关性分类。本节采用双分支分类器显式建模图文间的语义与情感相关性，并据此构建动态门控机制。首先构造相关性判别提示词，语义相关性输入 P_{relSem} 设定为 “Task: Analyze the semantic relevance of aspect x^a in the image and text: x^s ”，情感相关性输入 P_{relEmo} 设定为 “Task: Analyze the emotional relevance of aspect x^a in the image: x^i ”。提示词经 T5 模型编码及平均池化后，得到文本特征向量 $\bar{\mathbf{T}}_{sem}$ 和 $\bar{\mathbf{T}}_{emo}$ 。

与此同时，Q-Former 提取的原始视觉特征 $\mathbf{V}_{sem}$ 和 $\mathbf{V}_{emo}$ 经由多层感知机 (MLP) 进行维度对齐，生成特征矩阵：

$$\mathbf{V}_{relSem} = \text{MLP}_{sem}(\mathbf{V}_{sem}) \in \mathbb{R}^{N_q \times d} \quad (4.3)$$

$$\mathbf{V}_{relEmo} = \text{MLP}_{emo}(\mathbf{V}_{emo}) \in \mathbb{R}^{N_q \times d} \quad (4.4)$$

其中 d 为隐藏层维度。对特征矩阵进行平均池化得到全局视觉向量 $\bar{\mathbf{V}}_{relSem}$ 和 $\bar{\mathbf{V}}_{relEmo}$ 后，将其与对应的文本向量拼接，输入二分类器预测相关性概率：

$$p_{sem} = \sigma(\text{MLP}_{cls}^{sem}([\bar{\mathbf{T}}_{sem}; \bar{\mathbf{V}}_{relSem}])) \in (0, 1) \quad (4.5)$$

$$p_{emo} = \sigma(\text{MLP}_{cls}^{emo}([\bar{\mathbf{T}}_{emo}; \bar{\mathbf{V}}_{relEmo}])) \in (0, 1) \quad (4.6)$$

上述概率值作为广播机制下的门控信号，对原始特征矩阵进行加权处理：

$$\tilde{\mathbf{V}}_{sem} = p_{sem} \cdot \mathbf{V}_{sem} \quad (4.7)$$

$$\tilde{\mathbf{V}}_{emo} = p_{emo} \cdot \mathbf{V}_{emo} \quad (4.8)$$

当预测为高相关时，模型倾向于保留对应的细粒度视觉特征，反之则抑制其输入。训练过程中，模型最小化二元交叉熵损失。语义相关性损失 $\mathcal{L}_{sem}$ 与情感相关性损失 $\mathcal{L}_{emo}$ 定义如下：

$$\mathcal{L}_{sem} = -[y_{sem}^* \log p_{sem} + (1 - y_{sem}^*) \log(1 - p_{sem})] \quad (4.9)$$

$$\mathcal{L}_{emo} = -[y_{emo}^* \log p_{emo} + (1 - y_{emo}^*) \log(1 - p_{emo})] \quad (4.10)$$

多角度相关性建模的总损失函数为两者之和：

$$\mathcal{L}_{rel} = \mathcal{L}_{sem} + \mathcal{L}_{emo} \quad (4.11)$$

4.2.3 单模态情感监督

为增强模型对单模态信息的捕捉能力，本章引入文本方面级情感分类与图像情感分类作为预热阶段的辅助任务。通过联合训练多模态主任务与单模态辅助任务，模型能更有效地理解各模态独立携带的情感信息。辅助任务被设定为标准的三分类问题，并利用第三章获取的单模态情感线索标签 (y_{txt} 和 y_{img}) 作为监督信号。

在文本分支中，构造输入 P_{txt} 为 “Task: Identify sentiment based on text. Sentence: x^s Aspect: x^a Output:”。该输入经 T5 编码后得到特征 $\mathbf{H}_{txtEmo}$ ：

$$\mathbf{H}_{txtEmo} = T5(P_{txt}) \quad (4.12)$$

随后通过 Softmax 层预测情感分布，并计算交叉熵损失：

$$p(y_{txt}) = \text{Softmax}(\mathbf{W}_{txt} \mathbf{H}_{txtEmo} + \mathbf{b}_{txt}) \quad (4.13)$$

$$\mathcal{L}_{txt} = -\log p(y_{txt}^*) \quad (4.14)$$

在图像分支中，构造输入 P_{img} 为 “Task: Identify sentiment based on image. Aspect:

x^a Output:”。图像特征 $\mathbf{V}_{emo}$ 首先经过 MLP 映射得到 $\mathbf{V}_{imgEmo}$:

$$\mathbf{V}_{imgEmo} = \text{MLP}_{imgEmo}(\mathbf{V}_{emo}) \quad (4.15)$$

该特征作为前缀嵌入，与文本特征拼接后输入 T5 模型，获取图像情感分类特征 $\mathbf{H}_{imgEmo}$:

$$\mathbf{H}_{imgEmo} = \text{T5}(P_{img}, \mathbf{V}_{imgEmo}) \quad (4.16)$$

同理，利用该特征预测情感分布并计算辅助损失:

$$p(y_{img}) = \text{Softmax}(\mathbf{W}_{img}\mathbf{H}_{imgEmo} + \mathbf{b}_{img}) \quad (4.17)$$

$$\mathcal{L}_{img} = -\log p(y_{img}^*) \quad (4.18)$$

单模态情感监督的总辅助损失为:

$$\mathcal{L}_{aux} = \mathcal{L}_{txt} + \mathcal{L}_{img} \quad (4.19)$$

4.2.4 自适应融合推理

基于预测的相关性概率 p_{sem} 和 p_{emo} ，模型动态调整视觉特征权重以实现自适应融合。多模态主任务的文本输入 P_{fuse} 构造为“Task: Combining information from image and sentence to identify the sentiment of aspect x^a in the sentence x^s ”。文本经 T5 Embedding 层得到表示 $\mathbf{E}_f$ 。将门控加权后的细粒度视觉特征 $\tilde{\mathbf{V}}_{sem}$ 和 $\tilde{\mathbf{V}}_{emo}$ 作为前缀与文本表示拼接，输入 T5 模型获取最终特征:

$$\mathbf{H}_{fuse} = \text{T5}([\tilde{\mathbf{V}}_{sem}; \tilde{\mathbf{V}}_{emo}; \mathbf{E}_f]) \quad (4.20)$$

该机制有效实现了图像情感与语义特征的自适应融合。在训练阶段，融合表示 $\mathbf{H}_{fuse}$ 输入 Softmax 层预测情感标签 y 的概率分布:

$$p(y) = \text{Softmax}(\mathbf{W}_{fuse}\mathbf{H}_{fuse} + \mathbf{b}_{fuse}) \quad (4.21)$$

主任务目标函数为最大化真实标签概率的交叉熵损失：

$$\mathcal{L}_{main} = -\log p(y) \quad (4.22)$$

4.2.5 多任务损失函数

本章提出的框架涵盖主任务损失 $\mathcal{L}_{main}$ 、多角度相关性损失 $\mathcal{L}_{rel}$ 以及单模态辅助监督损失 $\mathcal{L}_{aux}$ 。为平衡多任务学习中的梯度冲突与收敛速度差异，引入基于同方差不确定性的自动加权策略^[71]，总损失函数定义为：

$$\mathcal{L}_{total} = \frac{1}{2\sigma_1^2} \mathcal{L}_{main} + \frac{1}{2\sigma_2^2} \mathcal{L}_{rel} + \frac{1}{2\sigma_3^2} \mathcal{L}_{aux} + \sum_{i=1}^3 \log \sigma_i \quad (4.23)$$

其中 σ_i 为各任务模块的可学习不确定性参数。当某任务的观测噪声较大（即 σ_i^2 增大）时，其损失权重将自动降低。

4.3 实验设置与结果分析

4.3.1 实验参数设置

本章沿用了与第三章一致的文本编码器、图像编码器、优化器配置及评价指标。针对两阶段训练策略，第一阶段冻结预训练语言模型主干，仅训练特征投影层与相关性判别头，并利用单模态情感监督辅助任务对模型进行预热。该阶段学习率设定为 $1e-3$ ，训练轮次为 5 轮，旨在使模型掌握文本和图像的基础情感特征。第二阶段则解冻所有参数进行端到端优化，学习率调整为 $5e-5$ ，训练轮次设为 10 轮。此外，损失函数中可学习不确定性参数的初始值设为 1，以支持模型在训练过程中根据各任务收敛难度自适应调整权重。

4.3.2 对比实验设置与结果分析

为了验证我们提出的多角度多任务框架的有效性，我们在 Twitter-15 和 Twitter-17 数据集上进行了对比实验。并对比了如下方法：

- ITM、HIMT、DPFN、Aom、Qwen2-VL 等：这些方法在上一章工作中已经介绍过，在此不再赘述。

表 4-1 对比实验结果

Methods	Twitter-15		Twitter-17	
	ACC	F1	ACC	F1
ITM	78.36	74.09	72.93	71.86
HIMT	76.37	72.01	68.82	66.88
DPFN	76.53	72.46	71.12	69.38
Aom	77.9	73.84	73.52	72.38
Qwen2-VL-7B	79.36	74.25	73.39	72.61
Qwen2.5-VL-7B	77.62	73.73	74.31	73.95
EC-EGC	77.91	75.27	74.80	74.36
Our Method	79.41	76.83	75.84	75.61

- EC-EGC: 该方法是第三章提出的图文情感线索引导的多模态情感分析方法, 通过引入细粒度的方面级跨模态情感相关性标签和单模态情感线索描述。

- Our Method: 该方法是我们提出的多角度多任务框架, 通过将方面级跨模态情感相关性解耦为情感相关性和语义相关性, 来分别控制图像情感特征和图像语义特征的细粒度使用。

根据表4-1, 我们可以看出 Our Method 在两个数据集上均取得了显著的性能提升。这一结果表明了 Our Method 在细粒度控制图像情感特征和图像语义特征的使用上, 能够更好地理解图文对中方面相关的情感相关性和语义相关性, 从而提升多模态方面级情感分类的性能。

4.3.3 消融实验分析

为了验证我们提出的多角度多任务框架的有效性, 在 Twitter-15 和 Twitter-17 数据集上进行了消融实验。消融实验对比了如下组件的效果:

- w/o Multi-level Relation Component: 表示完全移除了多角度相关性建模部分和相关性融合作用于图像特征部分, 仅保留了单模态情感监督部分。

- w/o Unimodal Sentiment Supervision Component: 表示完全移除了单模态情感监督部分, 仅保留了多角度相关性建模部分和相关性融合作用于图像特征部分。

- w/o Unimodal Sentiment Supervision Component: 表示完全移除了单模态情感监督和多角度相关性建模部分。

表 4-2 消融实验结果

Model Name	Twitter-15		Twitter-17	
	ACC	F1	ACC	F1
Our Method	79.41	76.83	75.84	75.61
w/o Multi-level Relation	77.44	74.63	73.64	73.47
w/o Unimodal Sentiment Supervision	77.93	75.21	74.19	74.09
w/o Unimodal Sentiment Supervision& Multi-level Relation	76.60	72.70	72.96	71.37

实验结果如表4-2所示，可以得出如下结论：

(1) 移除任意模块后模型的 ACC 和 F1 均会下降，验证了单模态情感监督和多角度相关性建模均可以帮助模型更好地理解图文对中方面的情感。当所有组件均移除时，模型性能最低，说明加入多角度相关性和单模态监督能够让模型更好地理解图文对。

(2) 与移除单模态情感监督的实验相比，移除多角度相关性的实验导致了模型显著的性能衰退。这一结果表明，单纯依赖单模态特征无法充分捕捉社交媒体语境下的复杂语义。多角度相关性模块通过挖掘文本与图像间的深层语义和情感关联，能够帮助模型更好地理解 and 利用这一关联来控制细粒度图像特征的使用，从而提升多模态情感分类的性能。

(3) 移除单模态情感监督后，模型性能同样出现了不同程度的下滑。这说明在多任务学习框架下，单模态的辅助监督信号能够有效规范特征学习空间，帮助模型分别理解好文本和图像各自的情感。防止模型在处理复杂的多模态交互时丢失原始模态的情感倾向信息，从而提升了模型的整体鲁棒性。

4.3.4 相关性分析

为了验证本章提出的多角度相关性的有效性，并探究不同粒度的相关性监督信号对模型性能的具体影响，本节在 Twitter-15 和 Twitter-17 两个数据集上进行了深入的对比实验。在完整的方法上设计了针对相关性的对比实验。包含以下四种设置：

-多角度相关性 (Multi-level Relevance): 即本章提出的完整方法，将本研究定义的方面级跨模态情感相关性解耦为情感相关性和语义相关性，分别控制图像情感特征和图像语义特征的细粒度使用。

表 4-3 相关性分析结果

Relevance Type	Twitter-15		Twitter-17	
	ACC	F1	ACC	F1
Multi-level Relevance	79.41	76.83	75.84	75.61
Fine-grained Relevance	77.81	75.34	74.11	73.96
Coarse-grained Relevance	76.92	74.12	73.27	72.94
w/o Relevance	77.44	74.63	73.64	73.47

-粗粒度相关性 (Coarse-grained Relevance): 仅考虑图像和方面是否相关。

-细粒度相关性 (Fine-grained Relevance): 将图文情感相关性分类为情感相关、语义相关和图文无关三种情况。

-忽略考虑相关性 (w/o Relevance): 在本章的方法中忽略考虑相关性的建模即对应仅使用单模态情感监督任务，不引入多角度相关性建模和相关性融合作用于图像特征的交互模块。

实验结果如表 4-3 所示，可以得出以下结论：本章提出的多角度相关性即 (Multi-level Relevance) 策略在两个数据集的所有指标上均取得了最优性能。我们认为这是以为引入特征解耦和方面级跨模态相关性解耦使得模型能够精确地分辨图像在语义层面和情感层面两个独立维度上的贡献。这种细粒度的控制使得模型在面对图文弱相关或存在视觉噪声的样本时，能够保留有益的视觉特征，从而大幅提升了多模态融合的鲁棒性。另外，粗粒度相关性策略 (Coarse-grained Relevance) 的性能反而低于忽略相关性 (w/o Relevance) 的模型。这是因为粗粒度策略强制使用同一个标量权重去同时控制图像的语义特征和情感特征。然而图像往往可能语义相关但情感无关，或者情感相关但语义无关如使用通用表情包。粗粒度的约束会导致模型在保留语义信息的同时引入情感噪声，或在过滤噪声的同时丢失关键语义线索。对比细粒度相关性 (Fine-grained Relevance) 其性能显著优于粗粒度模型和基准模型。这表明区分语义和情感维度的必要性。然而，细粒度策略仍落后于本章的多角度策略。这是因为本章的多角度相关性策略将语义门控和情感门控视为两个独立任务实现了特征级别的软性解耦，从而提供了更灵活的特征融合。

图 4-2 样例分析结果

Image-Text Pair	Unimodal Sentiment	Relevance	Prediction
Here you go [Dallas] fans . 	Neutral Negative	the semantic relevance is relevant, the emotional relevance is relevant $Rel_{sen}: 0.14$ $Rel_{sem}: 0.77$	Gold: Negative RC-ECG: Neutral ✗ DMRD-MASC: Negative ✓
Bad wreck on i40 near [Sandy Ridge Road] , one lane blocked , traffic very slow . 	Neutral Negative	the semantic relevance is irrelevant, the emotional relevance is irrelevant $Rel_{sen}: 0.22$ $Rel_{sem}: 0.19$	Gold: Neutral RC-ECG: Negative ✗ DMRD-MASC: Neutral ✓

4.3.5 样例分析

为了直观验证本章方法 (DMRD-MASC) 在复杂多模态语境下的有效性, 图4-2展示了两个典型样例与第三章方法 (RC-ECG) 的预测对比。在第一个样中, 文本字面偏中立但配图传达了强烈的负面情感, 构成了一种语义无关但情感相关的表情包恶搞语境。RC-ECG 方法因依赖细粒度相关性约束, 在面对图文实体语义不匹配时, 引入无关的视觉语义特征干扰判断, 从而错误预测为中性。而本章方法通过多角度相关性建模解耦了视觉特征, 在过滤无关图像语义的同时精准保留了其负面情感特征, 促使模型准确捕捉到反讽语气并预测为负极性。另外在第二个样例中, 文本仅客观描述交通状况, 但配图具有极强的负面视觉冲击力。RC-ECG 方法由于直接将情感线索描述输入模型, 缺乏对单模态表征的独立约束; 相比之下, 本章方法通过引入单模态情感监督辅助任务, 显著增强了模型对文本模态“客观陈述”本质的独立判别能力, 同时结合多角度相关性机制准确识别出图文在语义和情感上的双重无关, 从而有效屏蔽了视觉情感噪声的侵蚀, 最终做出了正确的中性预测。该结果表明多角度相关性建模与单模态辅助监督能够使模型显著提升了多模态方面级情感分析的鲁棒性。

4.4 本章小结

本章主要介绍了我们提出的多角度多任务框架 (DMRD-MASC), 该框架通过将方面级跨模态情感相关性解耦为情感相关性和语义相关性, 分别控制图像情感特征和图像语义特征的细粒度使用。在 Twitter-15 和 Twitter-17 数据集上的实验结果表明,

本章提出的多角度相关性策略在两个数据集上均取得了最优性能。除此之外还对比了不同粒度的相关性监督信号对模型性能的具体影响，发现细粒度相关性能够更准确地捕捉图文对中情感关联，而粗粒度相关性则在某些情况下可能引入噪声干扰。最后，我们通过样例分析验证了本章方法在复杂多模态语境下的有效性。

第五章 总结与展望

5.1 研究工作总结

本文的主要内容在前面章节中已经介绍，本章在此基础上对本文的研究工作进行总结：

(1) 方面级图文情感相关性语料构建与数据分析：本研究从图文关系的视角出发，针对现有图文关系定义仅关注文本与图像的显式对齐或全局相关性，而忽略隐式情感关联，导致模型在复杂场景下易受干扰的问题，定义了基于情感表达的方面级跨模态相关性，并构建了一个新的方面级图文相关性数据集。在此基础上，本研究对该数据集进行了详细的统计分析，深入探究图文关系与情感之间的内在关联，为后续研究奠定了数据基础。同时，通过在多个数据集上将跨模态相关性信息融入多种多模态方面级情感分类模型进行对比实验，验证了所提出的方面级跨模态相关性的有效性。

(2) 基于图文情感线索引导的多模态方面级情感分析：尽管前述工作验证了加入本文提出的方面级跨模态相关性能带来性能提升，但仅依靠粗粒度的相关性难以精确控制图像模态的贡献，且模型无法精确捕捉单模态中各自蕴含的情感线索，导致模型在情感分析场景下的鲁棒性不足。因此，本研究提出了基于图文情感线索引导的多模态方面级情感分析方法。针对现有方法对图文情感线索建模粒度不足的问题，该方法利用多模态大模型提取与方面相关的情感线索描述，将其作为补充信息编码至上下文；同时利用细粒度方面级跨模态相关性作为引导信号，控制图文情感线索与图文特征的细粒度融合，有效抑制无关或冲突线索的干扰，从而提升模型对图文情感的理解能力。

(3) 基于多角度图文相关性解耦的多模态方面级情感分析：为了进一步提升模型对复杂图文的理解能力和情感识别能力，同时减少无关图像语义噪声的引入，本章提出了一种基于多角度图文相关性解耦的多模态方面级情感分析方法。为了实现对图像特征的精细化控制，本研究将方面级跨模态相关性进一步解耦为语义相关性与情感相关性两个独立维度进行建模。具体而言，模型分别提取图像中的语义特征和情感特征，并利用解耦后的多角度相关性概率作为门控引导信号；这一机制能够在有效过滤无关语义干扰的同时，针对性地增强关键情感特征的融合与利用。此外，为了夯实多角度相关性建模的基础，本研究引入了单模态情感监督辅助任务。该机制将情感线

索从原本的输入端提示转化为训练阶段的监督信号，通过多任务学习促使模型主动习得鲁棒的单模态情感表征，从而显著提升模型在复杂场景下的情感分析能力与鲁棒性。

5.2 下一步工作设想

虽然本文在基于图文关系的多模态情感分析上取得一定研究成果，但后续工作还需要在以下方面进行进一步探索：

首先，为了进一步提升模型在处理反讽、隐喻等高阶语义复杂场景下的表现，后续研究将探索多模态大模型与思维链技术的深度融合。现有的解耦机制虽然有效过滤了噪声，但在解释“为何图文相关”的逻辑层面仍有提升空间。未来的工作计划利用大模型的生成能力，不仅仅提取情感线索，而是生成显式的推理路径，将隐式的跨模态情感关联转化为可解释的逻辑链条。通过知识蒸馏或参数高效微调技术，将这种深层的推理能力注入到本研究提出的轻量级模型中，从而在保持计算效率的同时，显著增强模型对于复杂图文语境的理解与推断能力。

其次，随着社交媒体内容形式的演变，将现有的静态图文分析框架扩展至视频多模态方面级情感分析是必然趋势。视频数据引入了时间维度与音频模态，带来了更高的数据冗余与对齐难度。考虑将方面级跨模态情感相关性的语义和情层面解耦的思想拓展至视频维度，设计一种动态的跨模态解耦机制。能够在从连续的视频帧序列与音频流中动态识别并分离出承载关键情感信息的情感片段，同时过滤掉仅包含背景语义的冗余帧与环境噪声。实现对动态流媒体内容的精准情感定位与分析。

最后，本研究主要聚焦于图文场景下的细粒度情感相关性解耦方法探索，并未对更广泛的下游任务进行实际应用。尽管已有的实验证明了多角度相关性建模对于提升情感分析性能的有效性，但是对于具体且复杂的多模态任务，如多模态反讽识别、跨模态虚假新闻检测以及面向开放域的舆情监控等，本研究的方法和模型还需要进一步验证。因此，未来的工作将致力于将本研究提出的模型框架迁移应用到这些具体的下游任务中，通过在真实且充满噪声的数据环境中进行测试，以全面验证其泛化能力与实用价值。

参考文献

- [1] Alamoodi A H, Zaidan B B, Zaidan A A, Albahri O S, Mohammed K I, Malik R Q, Almahdi E M, Chyad M A, Tareq Z, Albahri A S, et al. Sentiment analysis and its applications in fighting covid-19 and infectious diseases: A systematic review [J]. Expert systems with applications, 2021, 167: 114155.
- [2] Yue L, Chen W, Li X, Zuo W, Yin M. A survey of sentiment analysis in social media [J]. Knowledge and information systems, 2019, 60(2): 617-663.
- [3] Wankhade M, Rao A C S, Kulkarni C. A survey on sentiment analysis methods, applications, and challenges [J]. Artificial intelligence review, 2022, 55(7): 5731-5780.
- [4] Das R, Singh T D. Multimodal sentiment analysis: a survey of methods, trends, and challenges [J]. ACM Computing Surveys, 2023, 55(13s): 1-38.
- [5] Vitman O, Kostiuk Y, Sidorov G, Gelbukh A. Sarcasm detection framework using context, emotion and sentiment features [J]. Expert Systems with Applications, 2023, 234: 121068.
- [6] Zhang Y, Wang J, Liu Y, Rong L, Zheng Q, Tiwari P, Song D, Qin J. M2seq2seq: A multi-task sequence to sequence learning model for multi-modal sarcasm, sentiment and emotion recognition in conversation [J]. Sentiment and Emotion Recognition in Conversation.
- [7] Zhang X, Cao J, Li X, Sheng Q, Zhong L, Shu K. Mining dual emotion for fake news detection [C]//Proceedings of the web conference 2021. 2021: 3465-3476.
- [8] Yang C, Zhu F, Liu G, Han J, Hu S. Multimodal hate speech detection via cross-domain knowledge transfer [C]//Proceedings of the 30th ACM International Conference on Multimedia. 2022: 4505-4514.
- [9] Zhao H, Yang M, Bai X, Liu H. A survey on multimodal aspect-based sentiment analysis [J]. IEEE Access, 2024, 12: 12039-12052.
- [10] Zhang W, Li X, Deng Y, Bing L, Lam W. A survey on aspect-based sentiment analysis: Tasks, methods, and challenges [J]. IEEE Transactions on Knowledge and Data Engineering, 2022, 35(11): 11019-11038.
- [11] Wang Y, Huang M, Zhu X, Zhao L. Attention-based lstm for aspect-level sentiment

- classification [C]//Proceedings of the 2016 conference on empirical methods in natural language processing. 2016: 606-615.
- [12] Chen P, Sun Z, Bing L, Yang W. Recurrent attention network on memory for aspect sentiment analysis [C]//Proceedings of the 2017 conference on empirical methods in natural language processing. 2017: 452-461.
- [13] Sun C, Huang L, Qiu X. Utilizing bert for aspect-based sentiment analysis via constructing auxiliary sentence [C]//Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers). 2019: 380-385.
- [14] Wang X, Liu P, Zhu Z, Lu R. Aspect-based sentiment analysis with graph convolutional networks over dependency awareness [C]//2022 26th International Conference on Pattern Recognition (ICPR). IEEE, 2022: 2238-2245.
- [15] Yuan L, Wang J, Yu L C, Zhang X. Syntactic graph attention network for aspect-level sentiment analysis [J]. IEEE Transactions on Artificial Intelligence, 2022, 5(1): 140-153.
- [16] Zadeh A, Chen M, Poria S, Cambria E, Morency L P. Tensor fusion network for multi-modal sentiment analysis [C]//Proceedings of the 2017 conference on empirical methods in natural language processing. 2017: 1103-1114.
- [17] Majumder N, Hazarika D, Gelbukh A, Cambria E, Poria S. Multimodal sentiment analysis using hierarchical fusion with context modeling [J]. Knowledge-based systems, 2018, 161: 124-133.
- [18] Ghosal D, Akhtar M S, Chauhan D, Poria S, Ekbal A, Bhattacharyya P. Contextual inter-modal attention for multi-modal sentiment analysis [C]//proceedings of the 2018 conference on empirical methods in natural language processing. 2018: 3454-3466.
- [19] Xu N, Mao W, Chen G. Multi-interactive memory network for aspect based multimodal sentiment analysis [C]//Proceedings of the AAAI conference on artificial intelligence: volume 33. 2019: 371-378.
- [20] Yu J, Jiang J. Adapting bert for target-oriented multimodal sentiment classification [C]// Proceedings of the Twenty-Eighth International Joint Conference on Artificial Intelligence. International Joint Conferences on Artificial Intelligence Organization, 2019: 5408-5414.

- [21] Yu J, Jiang J, Xia R. Entity-sensitive attention and fusion network for entity-level multimodal sentiment classification [J]. *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, 2019, 28: 429-439.
- [22] Wang D, Tian C, Liang X, Zhao L, He L, Wang Q. Dual-perspective fusion network for aspect-based multimodal sentiment analysis [J]. *IEEE Transactions on Multimedia*, 2024, 26: 4028-4038.
- [23] Xiao L, Wu X, Yang S, Xu J, Zhou J, He L. Cross-modal fine-grained alignment and fusion network for multimodal aspect-based sentiment analysis [J]. *Information Processing & Management*, 2023, 60(6): 103508.
- [24] Zhao F, Wu Z, Long S, Dai X, Huang S, Chen J. Learning from adjective-noun pairs: A knowledge-enhanced framework for target-oriented multimodal sentiment classification [C]//*Proceedings of the 29th International Conference on Computational Linguistics*. International Committee on Computational Linguistics, 2022: 6784-6794.
- [25] Ju X, Zhang D, Xiao R, Li J, Li S, Zhang M, Zhou G. Joint multi-modal aspect-sentiment analysis with auxiliary cross-modal relation detection [C]//*Proceedings of the 2021 conference on empirical methods in natural language processing*. 2021: 4395-4405.
- [26] Yu J, Wang J, Xia R, Li J. Targeted multimodal sentiment classification based on coarse-to-fine grained image-target matching [C]//*Proceedings of the Thirty-First International Joint Conference on Artificial Intelligence*. International Joint Conferences on Artificial Intelligence Organization, 2022: 4482-4488.
- [27] Feng J, Lin M, Shang L, Gao X. Autonomous aspect-image instruction a2ii: Q-former guided multimodal sentiment classification [C]//*Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation*. 2024: 1996-2005.
- [28] Wang W, Ding L, Shen L, Luo Y, Hu H, Tao D. Wisdom: Improving multimodal sentiment analysis by fusing contextual world knowledge [C]//*Proceedings of the 32nd ACM International Conference on Multimedia*. 2024: 2282-2291.
- [29] Yang L, Na J C, Yu J. Cross-modal multitask transformer for end-to-end multimodal aspect-based sentiment analysis [J]. *Information Processing & Management*, 2022, 59(5): 103038.

- [30] Ling Y, Yu J, Xia R. Vision-language pre-training for multimodal aspect-based sentiment analysis [C]//Proceedings of the 60th annual meeting of the association for computational linguistics (volume 1: long papers). 2022: 2149-2159.
- [31] Zhou R, Guo W, Liu X, Yu S, Zhang Y, Yuan X. AoM: Detecting aspect-oriented information for multimodal aspect-based sentiment analysis [C]//Findings of the Association for Computational Linguistics. Association for Computational Linguistics, 2023: 8184-8196.
- [32] Chen Z, Zhu Z, Xu W, Zhang Y, Wu X, Zheng Y. Aspects are anchors: Towards multimodal aspect-based sentiment analysis via aspect-driven alignment and refinement [C]//Proceedings of the 32nd ACM International Conference on Multimedia. 2024: 2292-2300.
- [33] Zhao F, Li C, Wu Z, Ouyang Y, Zhang J, Dai X. M2df: multi-grained multi-curriculum denoising framework for multimodal aspect-based sentiment analysis [C]//Proceedings of the 2023 conference on empirical methods in natural language processing. 2023: 9057-9070.
- [34] Mu J, Nie F, Wang W, Xu J, Zhang J, Liu H. Mocolnet: A momentum contrastive learning network for multimodal aspect-level sentiment analysis [J]. IEEE Transactions on Knowledge and Data Engineering, 2023, 36(12): 8787-8800.
- [35] Yang X, Feng S, Wang D, Sun Q, Wu W, Zhang Y, Hong P, Poria S. Few-shot joint multimodal aspect-sentiment analysis based on generative multimodal prompt [C]//Findings of the association for computational linguistics: ACL 2023. 2023: 11575-11589.
- [36] Xiao L, Wu X, Xu J, Li W, Jin C, He L. Atlantis: Aesthetic-oriented multiple granularities fusion network for joint multimodal aspect-based sentiment analysis [J]. Information Fusion, 2024, 106: 102304.
- [37] Yang L, Wang J, Na J C, Yu J. Generating paraphrase sentences for multimodal entity-category-sentiment triple extraction [J]. Knowledge-Based Systems, 2023, 278: 110823.
- [38] Yang L, Wang Z, Li Z, Na J C, Yu J. An empirical study of multimodal entity-based sentiment analysis with chatgpt: Improving in-context learning via entity-aware contrastive learning [J]. Information Processing & Management, 2024, 61(4): 103724.

- [39] Marsh E E, Domas White M. A taxonomy of relationships between images and text [J]. *Journal of documentation*, 2003, 59(6): 647-672.
- [40] Lenth R V. Computer intensive methods for testing hypotheses: An introduction [M]. Taylor & Francis, 1990.
- [41] Martinec R, Salway A. A system for image-text relations in new (and old) media [J]. *Visual communication*, 2005, 4(3): 337-371.
- [42] Chen T, Lu D, Kan M Y, Cui P. Understanding and classifying image tweets [C]// *Proceedings of the 21st ACM international conference on Multimedia*. 2013: 781-784.
- [43] Vempala A, Preoțiuc-Pietro D. Categorizing and inferring the relationship between the text and image of twitter posts [C]// *Proceedings of the 57th annual meeting of the Association for Computational Linguistics*. 2019: 2830-2840.
- [44] Wang Z, Cui P, Xie L, Zhu W, Rui Y, Yang S. Bilateral correspondence model for words-and-pictures association in multimedia-rich microblogs [J]. *ACM Transactions on Multimedia Computing, Communications, and Applications*, 2014, 10(4): 1-21.
- [45] Xu N, Wang J, Tian Y, Zhang R, Mao W. Ananet: Association and alignment network for modeling implicit relevance in cross-modal correlation classification [J]. *IEEE Transactions on Multimedia*, 2022, 25: 7867-7880.
- [46] Chen D, Su W, Wu P, Hua B. Joint multimodal sentiment analysis based on information relevance [J]. *Information Processing & Management*, 2023, 60(2): 103193.
- [47] Radford A, Kim J W, Hallacy C, Ramesh A, Goh G, Agarwal S, Sastry G, Askell A, Mishkin P, Clark J, et al. Learning transferable visual models from natural language supervision [C]// *International conference on machine learning*. PmLR, 2021: 8748-8763.
- [48] Li J, Selvaraju R, Gotmare A, Joty S, Xiong C, Hoi S C H. Align before fuse: Vision and language representation learning with momentum distillation [J]. *Advances in neural information processing systems*, 2021, 34: 9694-9705.
- [49] Cheng Y, Zhu X, Qian J, Wen F, Liu P. Cross-modal graph matching network for image-text retrieval [J]. *ACM Transactions on Multimedia Computing, Communications, and Applications (TOMM)*, 2022, 18(4): 1-23.
- [50] Huang Z, Niu G, Liu X, Ding W, Xiao X, Wu H, Peng X. Learning with noisy correspondence for cross-modal matching [J]. *Advances in Neural Information Processing*

- Systems, 2021, 34: 29406-29419.
- [51] Ling Y, Yu J, Xia R. Vision-language pre-training for multimodal aspect-based sentiment analysis [C]//Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). Association for Computational Linguistics, 2022: 2149-2159.
- [52] Peng T, Li Z, Wang P, Zhang L, Zhao H. A novel energy based model mechanism for multi-modal aspect-based sentiment analysis [C]//Proceedings of the AAAI Conference on Artificial Intelligence: volume 38. 2024: 18869-18878.
- [53] Huang W, Wang Y, Gan Z, Xi T, Xi J, Xu X, Liu T, Qi D, Liu W. An opinion leader mining method based on text contents and network features [J]. World Wide Web, 2025, 28(2): 21.
- [54] Zhang X, Xie R, Lyu Y, Xin X, Ren P, Liang M, Zhang B, Kang Z, de Rijke M, Ren Z. Towards empathetic conversational recommender systems [C]//Proceedings of the 18th ACM Conference on Recommender Systems. 2024: 84-93.
- [55] Luvembe A M, Li W, Li S, Liu F, Xu G. Dual emotion based fake news detection: A deep attention-weight update approach [J]. Information Processing & Management, 2023, 60(4): 103354.
- [56] Liu Y. Roberta: A robustly optimized bert pretraining approach [J]. arXiv preprint arXiv:1907.11692, 2019.
- [57] Devlin J, Chang M W, Lee K, Toutanova K. BERT: Pre-training of deep bidirectional transformers for language understanding [C]//Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers). Association for Computational Linguistics, 2019: 4171-4186.
- [58] Ren S, He K, Girshick R, Sun J. Faster r-cnn: Towards real-time object detection with region proposal networks [J]. IEEE transactions on pattern analysis and machine intelligence, 2016, 39(6): 1137-1149.
- [59] Dosovitskiy A, Beyer L, Kolesnikov A, Weissenborn D, Zhai X, Unterthiner T, Dehghani M, Minderer M, Heigold G, Gelly S, et al. An image is worth 16x16 words: Transformers for image recognition at scale [J]. arXiv preprint arXiv:2010.11929, 2020.

- [60] Yu J, Chen K, Xia R. Hierarchical interactive multimodal transformer for aspect-based multimodal sentiment analysis [J]. IEEE Transactions on Affective Computing, 2023, 14(3): 1966-1978.
- [61] Tsai Y H H, Bai S, Liang P P, Kolter J Z, Morency L P, Salakhutdinov R. Multimodal transformer for unaligned multimodal language sequences [C]//Proceedings of the conference. Association for computational linguistics. Meeting: volume 2019. 2019: 6558.
- [62] Hu E J, Shen Y, Wallis P, Allen-Zhu Z, Li Y, Wang S, Wang L, Chen W, et al. Lora: Low-rank adaptation of large language models. [J]. Iclr, 2022, 1(2): 3.
- [63] Dai W, Li J, LI D, Tiong A, Zhao J, Wang W, Li B, Fung P N, Hoi S. Instructblip: Towards general-purpose vision-language models with instruction tuning [C]//Advances in Neural Information Processing Systems: volume 36. Curran Associates, Inc., 2023: 49250-49267.
- [64] Wang P, Bai S, Tan S, Wang S, Fan Z, Bai J, Chen K, Liu X, Wang J, Ge W, et al. Qwen2-vl: Enhancing vision-language model's perception of the world at any resolution [J]. arXiv preprint arXiv:2409.12191, 2024.
- [65] Bai S, Chen K, Liu X, Wang J, Ge W, Song S, Dang K, Wang P, Wang S, Tang J, et al. Qwen2. 5-vl technical report [J]. arXiv preprint arXiv:2502.13923, 2025.
- [66] Chung H W, Hou L, Longpre S, Zoph B, Tay Y, Fedus W, Li Y, Wang X, Dehghani M, Brahma S, et al. Scaling instruction-finetuned language models [J]. Journal of Machine Learning Research, 2024, 25(70): 1-53.
- [67] Colin R. Exploring the limits of transfer learning with a unified text-to-text transformer [J]. J. Mach. Learn. Res., 2020, 21.
- [68] Fang Y, Wang W, Xie B, Sun Q, Wu L, Wang X, Huang T, Wang X, Cao Y. Eva: Exploring the limits of masked visual representation learning at scale [C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2023: 19358-19369.
- [69] Dai W, Li J, Li D, Tiong A, Zhao J, Wang W, Li B, Fung P N, Hoi S. Instructblip: Towards general-purpose vision-language models with instruction tuning [J]. Advances in neural information processing systems, 2023, 36: 49250-49267.
- [70] Loshchilov I, Hutter F. Decoupled weight decay regularization [J]. arXiv preprint arXiv:1711.05101, 2017.

- [71] Kendall A, Gal Y, Cipolla R. Multi-task learning using uncertainty to weigh losses for scene geometry and semantics [C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 7482-7491.

攻读学位期间的成果

• 论文

(1) **Yu Zhang**, Zhenghua Li, Min Zhang. 2020. Efficient Second-Order TreeCRF for Neural CRF Dependency Parsing. In Proceedings of ACL, pages 3295–3305, Online. (CCF-A 类会议)

(2) **Yu Zhang**^{*}, Houquan Zhou^{*}, Min Zhang. 2020. Fast and Accurate Neural CRF Constituency Parsing. In Proceedings of IJCAI, pages 4046–4053, Online. (CCF-A 类会议)

(3) Houquan Zhou^{*}, **Yu Zhang**^{*}, Zhenghua Li, Min Zhang. 2020. Is POS Tagging Necessary or Even Helpful for Neural Dependency Parsing?. In Proceedings of NLPCC, pages 179–191, Zhengzhou, China (CCF-C 类会议, *Best Paper Award*)

(4) Wei Jiang, Zhenghua Li, **Yu Zhang**, Min Zhang. 2019. HLT@SUDA at SemEval 2019 Task 1: UCCA Graph Parsing as Constituent Tree Parsing. In Proceedings of SemEval, pages 11–15, Minneapolis, Minnesota, USA.

• 比赛

(1) 2020 语言与智能技术竞赛比赛，第六名。

(2) 2019 语义分析国际评测比赛，第一名。

• 实习

(1) 2020/8--2021/2. 杭州-阿里巴巴-达摩院。

致谢

养天地正气，法古今完人。从本科到硕士，转眼间在美丽的苏州大学校园内度过了七年的求学时光。在这段不算短的人生旅途中，无论是学识上还是生活阅历上我都成长良多。

首先，我要感谢我的导师李正华老师。李老师永远以饱满的热情和专注的态度面对工作和生活，永远是我以后求学和工作的一個榜样。

感谢尊敬的张民老师，张老师以高标准要求每一个学生，营造了组内浓厚专一的科研氛围。此外，张老师敏锐的思维、渊博的知识、平易近人的风格、深深的影响了我，平时的相处让我获益良多。感谢陈文亮老师，陈老师开朗热情，在学业上给予了我很多指导。同样感谢周国栋、朱巧明、李寿山、洪宇、段湘煜和李军辉等苏州大学自然语言处理实验室的所有老师，各位老师严谨的治学态度和进取的专业精神是我的榜样。

感谢周厚全师弟，厚全师弟涉猎广博，热爱阅读，富有好奇心，在平时的讨论中总是能给我很多启发。在课题研究上我们有很多合作，也取得了很多成果，希望以后继续合作，互相促进。

感谢同组的夏庆荣师兄、龚晨师姐、李英师姐和张月师姐，各位师兄师姐总是十分热心的解决我生活和研究上遇到的困难。感谢章波、黄德朋、江心舟师兄，彭雪师姐，在我还是萌新的时候对我的帮助，以及平时对我的关照。感谢同届的蒋炜、陆凯华、吴锟、刘亚慧同学，大家在一起互相帮助，互相进步。感谢沈嘉钰、李嘉诚、侯洋、李帅克、周仕林、刘泽洋、李扬师弟，还有周明月、杨浩萍师妹，十分珍惜与大家相处的美好时光。

此外，还要感谢实习期间相处的王涛师兄、蒋勇师兄，以及王新宇、胡泽川、蔡炯和马欣尹同学。特别是感谢蒋勇师兄在我实习期间对我的关照，以及在课题研究上的悉心帮助和指导。

感谢我的父母还有家人们，你们总是我心灵上的港湾和寄托，无论何时都能给我最无私的帮助。

最后，我还要感谢各位评审老师，感谢各位老师们在百忙之中抽取时间对本文进行评审，并提出宝贵的修改意见。

学位论文答辩委员会决议

- 包括：1、对论文的评价，包括选题的理论价值和实践意义，论文理论、方法上的开拓与创新，论据的可靠充分与结论的正确性；论文所反映的作者学术视野（对本学科及相关领域研究动态的把握）、基础理论、专业知识、写作能力等；
- 2、对答辩的评价；
- 3、是否同意通过论文答辩，是否建议授予学位或是否建议在规定时间内修改论文后重新答辩一次的结论。

论文在依存句法分析和成分句法分析这两种句法分析任务上，探讨了基于树形条件随机场的高阶方法对句法分析器性能和效率的影响。选题具有很好的理论价值和实践意义，以及一定的创新性。目前主流的句法分析方法大多基于神经网络方法，并采用了一个简化的学习目标，相对应地，传统方法中大多采用了结构化学习以及高阶建模。论文针对这一对比，提出了将当前的句法分析器与传统方法做一个联结。论文提出在神经网络模型中采用树形条件随机场来最大化树概率，并进一步提出采用高阶建模。为了改善带来的效率问题，论文分别尝试了批次化计算和变分推断近似方法来加速。结果表明结构化建模和高阶方法对于目前的句法分析器仍然是有益的。

作者比较全面地论述了相关研究领域国内外研究情况，所采用的研究方法和技术手段体现了作者良好的学术研究基础和能力。论文成果在研究方法等方面有所创新，其中的新方法、新思路具备了很好的应用价值。论文写作层次清晰，逻辑结构合理，文字流畅，符合学术规范。

论文质量优秀。答辩过程中陈述清楚，回答问题准确。

答辩委员会经讨论，认为该论文已达到硕士学位论文水平，一致同意其通过论文答辩，建议授予硕士学位。

答辩委员会主席：_____孔芳_____ 秘书：_____张雅静_____

委员：_____陈文亮_____、_____李培峰_____、_____钱龙华_____、_____朱晓旭_____

_____、_____、_____、_____

2021 年 5 月 22 日

注：本表内容（包括答辩名单）可手签或打印